

## 可视化与人工智能交叉研究综述

夏佳志\*, 李杰\*, 陈思明\*, 秦红星\* and 刘世霞\*

Citation: [中国科学: 信息科学](#) **51**, 1777 (2021); doi: 10.1360/SSI-2021-0062

View online: <https://engine.scichina.com/doi/10.1360/SSI-2021-0062>

View Table of Contents: <https://engine.scichina.com/publisher/scp/journal/SSI/51/11>

Published by the [《中国科学》杂志社](#)

---

### Articles you may be interested in

[GIS与人工智能结合下的三维可视化滑坡危险度评价](#)

Science in China Series E-Technological Sciences (in Chinese) **33**, 79 (2003);

[《模式识别与人工智能》投稿指南](#)

Pattern Recognition and Artificial Intelligence **33**, 1054 (2020);

[《模式识别与人工智能》投稿指南](#)

Pattern Recognition and Artificial Intelligence **33**, 670 (2020);

[《模式识别与人工智能》投稿指南](#)

Pattern Recognition and Artificial Intelligence **33**, 190 (2020);

[《模式识别与人工智能》投稿指南](#)

Pattern Recognition and Artificial Intelligence **33**, 723 (2020);

---



# 可视化与人工智能交叉研究综述

夏佳志<sup>1\*</sup>, 李杰<sup>2\*</sup>, 陈思明<sup>3</sup>, 秦红星<sup>4</sup>, 刘世霞<sup>5</sup>

1. 中南大学计算机学院, 长沙 410083

2. 天津大学智能与计算学部, 天津 300072

3. 复旦大学大数据学院, 上海 200433

4. 重庆大学计算机学院, 重庆 400044

5. 清华大学软件学院, 北京 100083

\* 通信作者. E-mail: xiajiazhi@csu.edu.cn, jie.li@tju.edu.cn

收稿日期: 2021-02-20; 接受日期: 2021-03-12; 网络出版日期: 2021-11-12

国家自然科学基金面上项目 (批准号: 61872389, 61972278, 61936002, 61772097)、国家重点研发计划 (批准号: 2018YFC0831700)、天津市自然科学基金 (批准号: 20JCQNJC01620)、上海市重大专项 (批准号: 2018SHZDZX01)、上海市自然科学基金项目面上项目 (批准号: 21ZR1403300)、上海市 2021 “科技创新行动计划” 扬帆计划 (批准号: 1YF1402900) 和重庆市自然科学基金 (批准号: cstc2018jcyjAX0177) 资助项目

**摘要** 随着人工智能技术的突破性进展, 人工智能与可视化的交叉研究成为当前的研究热点之一, 为人工智能和大数据分析领域的若干核心难题提供了启发式的理论、方法和技术. 一方面, 人工智能技术的创新应用提升了可视化的分析效率, 拓展了分析功能, 为大数据可视分析提供了强有力的工具. 另一方面, 可视化技术增强了以深度学习为代表的人工智能的可解释性和交互性, 为可解释人工智能提供了可靠的技术基础. 本文从面向人工智能的可视化技术和人工智能驱动的可视化技术两个方向, 分别介绍了数据质量改善、可解释机器学习、智能特征提取、可视化自动布局与生成、智能交互、智能故事叙述等 6 个重要问题. 对国内外的研究进展进行了分析, 并对发展趋势进行了展望.

**关键词** 可视化, 可视分析, 人工智能, 可解释机器学习, 自动可视化

## 1 引言

可视化与可视分析利用高带宽的视觉感知通道, 将数据转换为图形表达, 辅以交互手段, 以增强人对数据的认知能力, 在态势感知、关联分析、决策辅助等方面展示了强大的赋能作用. 随着以深度学习为代表的人工智能技术的突破性进展, 面向人工智能的可视化 (VIS for AI) 和人工智能驱动的可视化 (AI for VIS) 受到了可视化、机器学习、数据挖掘等领域的高度关注.

一方面, 可视化与可视分析在改善人工智能的基础数据质量和可解释性方面发挥了巨大作用<sup>[1]</sup>. 高质量训练数据是高性能人工智能应用的必要前提. 针对异常检测、数据标记等需要大量人工劳动的

**引用格式:** 夏佳志, 李杰, 陈思明, 等. 可视化与人工智能交叉研究综述. 中国科学: 信息科学, 2021, doi: 10.1360/SSI-2021-0062  
Xia J Z, Li J, Chen S M, et al. A survey on interdisciplinary research of visualization and artificial intelligence (in Chinese). Sci Sin Inform, 2021, doi: 10.1360/SSI-2021-0062

任务, 利用可视化与可视分析技术提高其效率, 是当前的研究热点之一<sup>[2~4]</sup>. 更令人关注的是人工智能的可解释性问题. 以深度神经网络为例, 它具有非线性非凸、多层结构、海量参数、弱语义特征等特点, 被认为是一个难以解释的“黑盒子”<sup>[5]</sup>. 在自动驾驶、智能医疗、金融投资等高风险决策领域, 可解释性成为阻碍领域技术发展的瓶颈问题. 可视化可以帮助提升机器学习的透明度, 增强人对大规模复杂机制的认知能力. 各领域在基于可视化的深度学习解释方法方面进行了大量的研究工作, 例如患者未来状态预测<sup>[6]</sup>、机器人训练策略<sup>[7]</sup>, 以及自然语言处理任务<sup>[8]</sup>.

另一方面, 人工智能技术的进步为可视化与可视分析的发展提供了强有力的工具. 针对复杂数据、复杂模式等需要呈现大量信息的可视化任务, 利用机器学习技术能够去除数据噪声、提取关键信息, 从而减少视觉混乱、增强可视化效果<sup>[9~11]</sup>. 同时, 利用人工智能技术拟合数据特征和可视编码也为可视化布局带来了新的机遇. 数据特征和可视编码的结合催生了更具表现力的可视化设计<sup>[12, 13]</sup>; 利用人工智能技术的海量数据自动化布局避免了耗时的数据操作和数据计算<sup>[14, 15]</sup>; 人工智能技术还被应用于解决大规模数据可视化中的交互效率难题, 例如体数据渲染中智能视角选择<sup>[16]</sup>、区块链智能合约交互式构建<sup>[17]</sup>和大型网络的交互式可视探索<sup>[10]</sup>.

因此, 有必要对“AI+VIS”这一研究趋势进行及时而全面的总结和分析. 在 VIS for AI 方面, 国内外学者展开了广泛研讨<sup>[18~21]</sup>. Yuan 等<sup>[1]</sup>对用于机器学习的可视分析技术进行了系统的调研, 并根据机器学习的流程提出了一个分类: 模型构建之前的技术、模型构建期间的技术以及模型构建之后的技术. Sacha 等<sup>[21]</sup>基于 21 篇代表性论文, 对 VIS4ML (面向机器学习的可视化) 的作用阶段和机制进行了分析, 提出了通用的概念本体. Hohman 等<sup>[19]</sup>对深度学习中的部分可视化技术进行了分类和总结, 从目的、使用者、可视化对象、可视化方法、使用阶段、应用场景等角度对相关论文进行了整理. Zhang 等<sup>[20]</sup>对卷积神经网络的可视化可解释方法进行了综述. Liu 等<sup>[18]</sup>从深度学习模型的理解、诊断和改进 3 个方面对可视化方法进行了综述. 但这些综述往往只包括了少部分工作<sup>[21]</sup>, 或涵盖的类型不全<sup>[19, 20]</sup>, 或未能包括最新的进展<sup>[18]</sup>. 在人工智能驱动的可视化方面, 目前还没有系统的综述. 因此, 我们从面向人工智能的可视化和人工智能驱动的可视化两个角度对当前的研究进展进行总结. 希望能够帮助可视化领域和人工智能领域的研究者增强对彼此工作的了解, 进一步促进可视化与人工智能交叉研究的发展.

## 2 面向人工智能的可视化

按照人工智能的处理阶段、可视化的对象和可视化的目的, 可以将人工智能中的可视化与可视分析技术归结为如下两类.

- 数据质量改善. 数据质量改善处于人工智能应用的前序阶段, 为其提供高质量的数据基础. 在这一阶段, 可视化的对象是各类基础数据. 由于数据规模和复杂性的快速增长, 传统的数据预处理方法面临着低处理效率、高人工代价等问题. 近年来, 可视化与可视分析被广泛应用于改善数据质量, 辅助数据处理与决策, 取得了较好的效果<sup>[22, 23]</sup>.
- 基于可视化的可解释机器学习. 模型构建与训练是人工智能技术的核心阶段. 在这一阶段, 可视化的对象包括模型结构、模型参数、模型输入、模型输出和各类中间数据. 可视化将这些数据转换为图形表达, 作为认知媒介, 并结合交互分析界面, 帮助专家理解、诊断和调试各类模型, 增强机器学习的可解释性和改善模型性能.

本节将对这两类工作近年来的进展分别进行阐述.

## 2.1 数据质量改善

可视化领域进行了大量关于数据质量改善的工作<sup>[24]</sup>. 数据质量缺乏一个统一的定义<sup>[25]</sup>. 但一般认为, 数据质量的定义与应用问题密切相关, 它表示数据在某一领域问题上可用的程度<sup>[26]</sup>. 近年来, 可视化领域关注的的数据质量问题主要包括数据异常、数据标签和数据隐私 3 个方面.

### 2.1.1 数据异常

异常是指数据中与正常行为不同的模式. 它是影响数据质量的重要因素. 一方面, 异常的定义依赖于具体场景和应用需求, 异常模式经常随着时间改变, 自动化检测方法难以准确捕捉所有类型的异常<sup>[27]</sup>; 另一方面, 自动化检测方法往往缺乏可解释性, 用户难以信任. 因此, 研究者采用可视化技术将各类数据映射为图形元素, 构造交互式分析环境, 以支持用户识别、理解 and 处理异常.

在检测高维数据中的异常时, 常用降维 + 散点图、平行坐标图等方法对高维数据集进行可视化, 以支持用户在视觉上识别异常. 例如, Butscher 等<sup>[28]</sup> 使用增强现实设备展示平行坐标图, 来协助用户识别高维数据中的异常. 但在数据维度增长时, 高维数据的投影区分效果下降较快, 而平行坐标图等方法则遇到了可伸缩性问题. 为此, Wilkinson<sup>[29]</sup> 提出了一个面向可视化的高维数据异常检测算法. 面对维度类型多样、高维、非正态分布等具有挑战性的数据特征, 这种方法能够取得较好的效果. 此外, Liu 等<sup>[3]</sup> 提出了检测训练数据集 Out-of-Distribution (OoD) 问题的可视分析方法. Cao 等则从可视化设计<sup>[30]</sup>、可视分析系统设计<sup>[31]</sup> 等方面对多维数据的异常展开了研究工作. Qu 等<sup>[32]</sup> 为多维数据中异常值的解释提出了可视分析解决方案.

时序数据中的异常也受到了大量的关注. 例如 Gschwandtner 等<sup>[33]</sup> 使用热力图呈现时序数据, 帮助发现异常. 对于较为复杂的数据类型, 研究者针对性地设计了数据表达与图形表达. 例如针对时序事件数据中的集体异常, Tao 等<sup>[34]</sup> 提出建立高阶关联图以表达事件之间的联系, 并设计了可视分析系统帮助用户进行交互式分析. Xie 等<sup>[35]</sup> 针对高性能计算中运行时行为异常检测问题, 将其归约为调用堆栈树的异常检测问题, 并采用投影、节点链接图等视图进行表达. Bögl 等<sup>[36]</sup> 针对多维周期数据异常, 提出了基于马氏距离的周期图. 更多的研究致力于大规模数据处理, 采用机器学习方法对异常进行直接检测或度量, 依据检测或度量结果推荐给用户, 并进行进一步的交互式分析<sup>[37,38]</sup>. 典型的工作包括分析网络安全流数据中的异常<sup>[39]</sup> 等. 针对带有缺失值的时序数据可视化问题, Song 等<sup>[40]</sup> 对折线图和柱状图等常用可视化方法的性能进行了评估, 并给出了使用建议. 此外, 还有部分研究与应用结合较为紧密, 例如 Qu 等的云计算系统异常性能检测<sup>[41]</sup>、慕课数据异常行为检测<sup>[42]</sup> 等工作, Cao 等关于智能工厂生产过程异常检测<sup>[43]</sup>、医疗检测数据异常检测<sup>[44]</sup> 的系列工作, Zhao 等关于无线通信异常检测<sup>[45]</sup>、智能工厂耐久测试异常检测<sup>[46]</sup> 等工作.

针对图数据, Fan 等<sup>[2]</sup> 提出结合主动学习的可视分析方法, 通过迭代标记来检测网络异常. 针对数据中的不确定性, Zhao 等<sup>[47]</sup> 对模糊聚类的可视化效果进行了评估. 在时空地理数据的异常发现方面, Cao 等<sup>[48~50]</sup> 进行了多项工作.

### 2.1.2 数据标签

数据标签是指附加到数据对象上的可被计算机识别和分析的关联信息. 它是有监督学习等多种机器学习、数据挖掘、数据分析应用中的必要信息<sup>[51]</sup>. 数据标记的时间成本和人力成本都比较高. 可视分析可以支持用户高效地探索和理解数据, 识别数据中类别、异常等模式, 加速数据标注的速度. 按照有无标签信息分类, 现有的可视分析工作可以分为标签质量改善和交互式标注两类.

针对分类标签错误, Xiang 等<sup>[52]</sup> 设计了层次化 t-SNE 方法以查看图像数据集, 结合自动纠正算

法, 迭代地对标签进行纠正 (请参考文献 [52] 中的图 1)。类似地, Bäuerle 等 [4] 设计了基于矩阵和散点图的可视化方法, 允许用户迭代地纠正错误标签和改进分类器性能。在众包模式中, 错误标签往往集中在部分参与人的标注结果上。针对该问题, Park 等 [53] 设计了一个可视分析系统, 用于改善临床图像数据众包标注参与人的工作质量。Liu 等 [54] 提出了交互式可视分析工具 LabelInspect, 以识别不可靠的标签实例和众包工人。

交互式标注通过可视化方法给无标签的数据进行标注, 可以分为两类策略。第 1 类是基于数据的策略, 通过可视化布局展示数据的相似关系, 或通过过滤和排序支持选择相似数据。Kurzahls 等 [55] 为了给视频标注感兴趣区域, 对视频的缩略图进行聚类并集中展示。Khayat 等 [56] 使用降维方法在散点图中揭示社交媒体用户行为的相似关系, 以帮助标注垃圾邮件机器人。Halter 等 [57] 则基于电影中使用的主要色彩策略进行布局。Rooij 等 [58] 使用属性对视频片段进行过滤; Stein 等 [59] 则提供了一个基于规则的过滤引擎来发现足球比赛视频的有趣模式。第 2 类是基于模型的策略, 将可视分析与主动学习模型结合 [60], 用户只需要标注少量范例输入到主动学习模型中, 通过迭代修改与学习完成标注任务。这一类方法还包括文本注释 [61]、轨迹分类 [62]、相关推特识别 [63] 和序列数据检索 [64] 等。Bernard 等 [65] 对两种策略进行了评估。结果表明, 在早期阶段基于数据的策略的效果较好。但在之后的阶段中, 基于模型的策略的效果会更好。此外, 协同众包方法也被用于数据标注 [66]。

### 2.1.3 数据隐私

在多个实际场景中, 数据隐私保护成为人工智能技术能否落地的先决问题。例如, 欧盟颁布的《通用数据保护条例》对数据隐私保护提出了严格的要求。近年来, 隐私保护在可视化与可视分析领域中受到越来越多的重视。与全自动化方法相比, 可视分析方法具有两个主要优势 [67]: (1) 可视化在整个隐私保护策略制定过程中提供了更好的透明度, 包括识别、检查和解决数据集中的隐私问题。用户可以从视觉上识别数据记录与指定标准之间的关联关系。此外, 可视化还提供了关于不同隐私保护策略对数据集影响的即时反馈; (2) 可视化可用于调节隐私保护和数据效用之间的平衡。用户可以方便地比较和查看不同隐私保护操作应用于特定问题的效果, 进而进行决策。Chou 等对此进行了多项研究, 包括社交网络数据的隐私保护 [68]、事件序列数据的隐私保护 [67], 以交互式地制定符合用户需求的混淆策略。他们还违反美学的图布局策略在隐私保护上的作用进行了用户研究 [69]。此外, Chen 等针对多属性表格数据 [70] 和图数据 [71] 分别提出了可视分析解决方案, 帮助用户理解和调整隐私保护策略。

数据隐私问题还发生在可视化生成的阶段。当数据分布在多个数据拥有方时, 生成一个统一的可视化结果往往需要多个数据拥有方将数据汇总或进行交换。而数据汇总或交换将泄露数据隐私。Xia 等 [72] 提出了安全多方投影技术, 在保护参与方数据隐私的前提下计算融汇多方数据的 t-SNE 投影, 为数据孤岛背景下的联合可视化提供了一个解决方案。

## 2.2 基于可视化的可解释机器学习

以深度学习为代表的人工智能技术在计算机视觉、语音识别、自然语言处理等领域获得了巨大的成功。但在自动驾驶、智能医疗、金融投资等高风险决策领域, 人工智能的可解释性遭到了质疑。深度神经网络具有非线性非凸、多层结构、海量参数、弱语义特征等特点, 被认为是一个难以解释的“黑盒子” [5]。即使是决策树、随机森林这样的传统机器学习模型, 在规模较大时也给有效认知造成了挑战。可视化将复杂数据和结构映射为图形元素作为理解模型的媒介, 在可解释机器学习的研究中被广泛采用 [73]。现有的可视分析技术聚焦于帮助理解机器学习模型的表现, 诊断训练过程中的问题, 指导专家

对机器学习模型进行调整和改进<sup>[18]</sup> (请参考文献 [18] 中的图 2). 从研究对象的角度划分, 本小节从以下 3 个方面对可解释机器学习中的可视化工作进行阐述: (1) 基于可视化的可解释机器学习理论; (2) 传统机器学习模型的可视化技术; (3) 深度学习模型的可视化技术.

### 2.2.1 基于可视化的可解释机器学习理论

机器学习的“可解释性”尚无明确定义, 不同研究人员对可解释性的理解存在着主观上的差别<sup>[74]</sup>. 泛言之, 可解释性的主要目的是以人类可以理解的方式描述模型的机制, 让用户觉得模型作出的决策合理可信<sup>[75]</sup>. 常见的解释方法可以分为“白盒”方法和“黑盒”方法.“白盒”方法通过展示模型内部的结构和运行过程, 增强用户对模型的理解. 而“黑盒”方法聚焦于模型的输入输出以及它们之间的映射关系.“黑盒”方法与模型结构无关, 具有比较好的模型普适性. 如 Wexler 等<sup>[76]</sup> 提出的“*What-If*”工具和 Hohman 等<sup>[77]</sup> 提出的 Gamut 系统给出了“黑盒”方案的样例. 交互式可视分析允许用户自由选取感兴趣的对象和参数进行观察和分析, 在两种方法的基础上增强了解释方法的自由度, 支持对比分析、稳健性分析等多种分析任务. Spinner 等<sup>[78]</sup> 总结了交互式可解释机器学习的概念模型. 模型状态包括了所有可能的状态空间. 解释器生成可视化和代理模型等形式的模型解释, 以及对模型状态进行改动的转移函数. 模型状态生成与解释生成迭代进行, 以支持对模型的理解、诊断和改进. Cheng 等<sup>[79]</sup> 对“白盒”解释方法、“黑盒”解释方法和交互式解释方法的效果进行了用户评估. 结果显示, 3 种方法都可以增强用户对模型的理解, 但“白盒”方法未能在主观上增强用户对模型的理解, 而交互式方法虽然在主客观上都增强了对模型的理解, 但无法提高用户对决策算法的信任度.

对人工智能的公平性的理解也是可解释机器学习的研究目标之一. 由于数据分布、标签错误, 以及模型学习能力等原因, 训练得到的模型可能会在不同群体中有不公平的表现. Cabrera 等<sup>[80]</sup> 设计了一个混合发起的可视分析系统, 支持用户对指定的或推荐的子群体进行公平性分析, 以发现机器学习模型在不同人群间的交叉偏差. Ahn 等<sup>[81]</sup> 针对输入输出空间和其间的映射中的偏差, 设计了可视分析系统, 以支持对偏差的理解、度量、识别和缓解. Yan 等<sup>[82]</sup> 提出基于因果关系对数据和模型中的公平性进行分析, 并设计了相应的可视分析系统.

### 2.2.2 传统机器学习模型的可视化

传统机器学习模型结构相对简单, 可解释性相对较强, 但一些传统机器学习模型的非线性、非凸本质造成其仍然难以被直观地解释. 为了帮助用户更好地理解、诊断和改进传统机器学习模型, 近年来仍有一些可视化工作对传统机器学习模型的可视化解释进行研究, 主要包括分类模型、回归模型、降维模型、聚类模型等.

分类模型的可视化解释主要针对两类问题, 其一是数据分布与特征如何影响分类结果, 其二是不同的分类模型如何进行比较性解释和评估, 并进而实现分类模型调优. 针对第 1 类问题, Krause 等<sup>[83]</sup> 利用聚合统计数据图和特征复合统计图, 方便用户探索正确/不正确分类中的数据分布和不同特征在分类中的作用; Ma 等<sup>[84]</sup> 则从脏数据的角度应用可视分析解释和探索分类模型的缺陷; Zhao 等<sup>[85]</sup> 提出了 iForest, 它利用特征分析和案例推理方法, 并结合随机森林内部决策路径的概览和细节可视化, 来解释随机森林模型预测决策结果; Liu 等<sup>[86]</sup> 开发了 BOOSTVis, 分别从类、实例、分类和特征级别建模和可视化提升树的训练过程, 来支持分析训练动态 (例如, 类级别的模型性能演化、实例级别的关系等)、诊断训练缺陷. 针对第 2 类问题, Ren 等<sup>[87]</sup> 通过计算和展示分类模型的表现度量提出了一个多类分类问题的模型表现可视化工具 Squares; Gleicher 等<sup>[88]</sup> 设计了一个可视系统以方便用户选择感兴趣的训练集和测试集对不同的分类模型输出结果进行比较; Cavallo 等<sup>[89]</sup> 把分类结果与时序数据同

时可视化, 从多个粒度进行模型比较; Mühlbacher 等<sup>[90]</sup> 通过可视化比较不同的路径从而帮助用户构建决策树。

回归模型的可视化用于指导生成或选择最优模型。Dingen 等<sup>[91]</sup> 和 Das 等<sup>[92]</sup> 通过交互可视系统实现了对多个回归模型的比较和参数选择, 从而快速选择最优模型; Zhang 等<sup>[93]</sup> 提出应用可视化方法监测逻辑回归中统计指标与变量关系, 发现更有价值的变量, 实现高质量的回归模型建模。

降维算法中数据的高维性和算法的非线性本质增加了对降维算法的理解困难。为了有效地解释降维算法, Cavallo 等<sup>[94]</sup> 引入正向投影和反向投影两种交互技术, 用于对降维数据进行动态推理; Dim-Reader<sup>[95]</sup> 通过对原始数据的微小扰动解释非线性降维算法; Kwon 等<sup>[96]</sup> 提出通过让用户交互定制非线性轴映射以深入分析数据。Li 等<sup>[97]</sup> 设计了一个探索性的可视分析系统, 该系统支持在聚类、实例和结构层次上对嵌入向量进行比较性可视化解释。Lu 等<sup>[98]</sup> 提出利用散点的线段编码梯度特征, 以解释非线性投影。Bian 等<sup>[99]</sup> 采用椭圆编码局部子空间的方向, 以帮助理解高维数据投影的局部子空间结构。

聚类模型的挑战在于聚类需求的不确定性。Cavallo 等<sup>[100]</sup> 应用“聚类漫游”可视化技术帮助用户选择聚类参数和评估不同聚类的质量; Kwon 等<sup>[101]</sup> 应用坐标可视化技术对聚类进行探索分析; Sacha 等<sup>[102]</sup> 提出了一个基于分区的多阶段可视分析方法来探索分析聚类; Yang 等<sup>[103]</sup> 则提出了层次聚类的交互操纵方法, 允许用户利用带约束的进化贝叶斯玫瑰树聚类算法来引导层次聚类结果 (请参考文献 [103] 中的图 1)。

对于隐马尔可夫模型 (hidden Markov models, HMMs), 解释模型输出、理解复杂的建模参数以及在临床上理解模式对医学专家来说仍然是一项挑战。为了解决这一问题, Kwon 等<sup>[104]</sup> 与临床科学家、统计学家和可视化专家进行了一项设计研究, 并提出了 DPVis, 将 HMMs 的模型参数和结果无缝地集成到可解释的交互式可视化中。

### 2.2.3 深度学习模型的可视化技术

深度学习模型的可视化技术是最近的研究热点。按可视化的数据对象划分, 深度学习模型的可视化技术可以分为 4 种: (1) 基于静态图像数据的方法; (2) 基于模型内部结构的方法; (3) 基于输入输出数据和模型性能统计数据的方法; (4) 基于代理模型的方法。

(1) 基于静态图像数据的方法。在机器学习和计算机视觉领域, 静态图像常被用于揭示卷积神经网络中神经元的语义信息和图像特征对神经网络特定行为的贡献。自然语言处理中也采用类似的静态特征来解释神经网络学到的信息。以静态图像为例, 这一类方法可以细分为 5 种技术<sup>[105~107]</sup>。

输入扰动: 这类技术通过为输入图像中的不同区域施加扰动, 并使用前向传播来度量对目标的影响, 以总结高度复杂的神经网络在图像中“寻找”的地方, 从而揭示真实图像中哪些区域对目标响应贡献最大<sup>[108, 109]</sup>。其结果通常是一个粗略的二维显著图, 它展示了图像每个区域对目标响应的重要性。

反卷积: 这类技术<sup>[110~115]</sup> 同样希望找出真实图像中对目标响应贡献最大的部分。与输入扰动相反, 它采用反向传播技术, 通过将低维神经元的特征图投影回输入图像, 从而将响应追溯到输入图像 (请参考文献 [111] 中的图 3), 基于反卷积的方法利用像素级的细粒度显著图, 直接进行了图像级别的特征分析, 进而揭示所学习的特征及其结构。

逆向编码: 与上述方法不同的是, 这类技术<sup>[116~118]</sup> 不关注单个网络神经元的响应, 而是计算特定层的集体响应 (称为编码) 模式。然后使用各种方法合成图像, 以在该层上得到相似的响应。比较这两幅图像可以揭示实际图像的哪些特征保留在所选层上。

激活最大化: 这一类技术的核心思想是寻找最大化激发某个神经元的对应输入图像。即通过对人



工合成的图像每个像素进行迭代更改,找到能最大限度激活神经元的图像,以捕获特定神经元的特征学习偏好.这类技术由 Erhan 等<sup>[119]</sup>提出,并被进一步大规模应用<sup>[116,120,121]</sup>.最近,研究人员也开始尝试对这类方法进行归纳总结<sup>[122]</sup>.通过这些工作,激活最大化已显示出强大的能力来解释神经元的偏好并识别 CNN 所学习的图像特征.

网络解剖:为了处理图像特征与清晰可解释的语义概念之间仍然缺少联系的问题,Bau 等<sup>[123]</sup>提出了网络解剖方法,将每个卷积神经元直接与特定的语义概念(例如颜色、纹理等)相关联.这类技术<sup>[123,124]</sup>通过寻找强烈响应具有特定语义概念的特定图像内容的神经元,能够测量神经元与语义概念之间的相关性.

(2) 基于模型内部结构的方法.模型的内部结构包括神经元和神经元之间的连接关系.基于内部结构的可视化方法一般采用节点链接图<sup>[125]</sup>,以直观地展示数据在网络中的流动情况,支持对数据和神经元之间关系的分析,在 TensorFlow 等深度学习框架中被广泛采用<sup>[126]</sup>.最近的研究包括 Liu 等<sup>[127~129]</sup>对模型结构的多项研究工作.例如,CNNVis 系统<sup>[127]</sup>将卷积神经网络的结构建模为有向无环图,节点表示神经元,边表示神经元之间的连接关系(参考文献<sup>[127]</sup>中的图 1);DGMTracker<sup>[128]</sup>则使用节点表示深度生成模型中不同的层(包括卷积层、采样层等),边表示层之间的连接关系,每个节点还集成折线图来展示层内部的训练动态;而 AEVis<sup>[129]</sup>除了将深度神经网络的层级结构建模为有向无环图,神经元级建模为矩阵形式的热力图之外,还提出了特征图级建模,将层内相似特征的神经元建模为欧拉图.Ming 等<sup>[8]</sup>和 Shen 等<sup>[130]</sup>则通过对隐藏单元和特征进行聚类揭示卷积神经网络的内部机制.Liu 等<sup>[131]</sup>提出了 DeepTracker,应用分层和立方体可视化方法来跟踪卷积神经网络训练过程中训练日志数据的动态变化,以分析神经元权重、验证图像和训练迭代之间的复杂关联.Wongsuphasawat 等<sup>[132]</sup>则提出了 TensorFlow Graph Visualizer,将运算表达为节点,运算之间的数据流动表达为边.

但深度学习模型规模庞大,给节点链接图方法带来了可伸缩性的挑战.Summit 系统<sup>[133]</sup>基于活跃程度对神经元及其之间的边进行过滤,以保留重要结构.TNNVis 系统<sup>[134]</sup>合并相似神经元,并过滤不活跃层,以缩小可视化网络结构的规模.ACTIVIS 系统<sup>[135]</sup>则采用矩阵形式的热力图对神经元进行可视化.与节点链接图相比,矩阵形式的热力图无法表达连接关系,但可以在相同空间内展示更多神经元,并方便在不同层、不同训练进程、不同数据的反应之间进行对比.

(3) 基于输入输出数据和模型性能统计数据的方法.与前两种方法不同,这一类方法将模型视为“黑盒子”,主要关注模型的输入输出和部分性能统计数据.例如 Rauber 等<sup>[136]</sup>对模型的最后一层隐藏层的表达进行投影,以跟踪和分析模型训练进程.Zhang 等<sup>[137]</sup>提出的 Manifold 系统通过分类结果比较多个不同模型,并分析哪些特征对模型输出有更大的影响.Murugesan 等<sup>[138]</sup>设计了 DeepCompare 系统,以比较两种深度学习模型的输出结果.NLIZE 系统<sup>[139]</sup>对输入数据、输出的预测概率和模型状态的统计信息进行可视化,并支持“what-if”形式的交互式分析,帮助用户理解当某一部分(例如输入数据)变化时,会给其他部分造成什么样的影响.Ming 等<sup>[140]</sup>使用可解释序列模型 ProSeNet<sup>[141]</sup>,从原始训练数据中构建一小组原型序列,并将新的输入与原型在一个潜在的推理空间中相比较以便进行推理,从而对深度序列模型进行解释和操纵.Kahng 等<sup>[142]</sup>提出的 GAN Lab 展示了生成网络的流程摘要、生成器和判别器的数据分布,以及模型性能参数,帮助普通用户理解生成对抗网络的训练过程.由于仅仅从模型中提取了有限的参数和性能统计信息,这些方法被称为探针式的方法.这一类方法与模型耦合程度不高,可较容易地应用于更多类型的模型.

(4) 基于代理模型的方法.与大规模神经网络相比,更小的神经网络,或线性回归等传统机器学习模型具有更好的可解释性.因此,一些研究者提出训练代理模型以模拟目标模型,帮助理解目标模型的决策机制.从使用者的角度来看,基于代理模型的方法将目标模型视为黑盒子,不需要了解目标模



型的内部, 属于模型无关的方法. Collaris 等<sup>[143]</sup> 为解释目标模型, 训练了一系列代理模型. 不同的代理模型具有不同的可解释性和准确性. 基于多种代理模型, 该可视分析系统支持用户自由选择模型和参数, 在准确性和可解释性之间取得需要的平衡. Wang 等<sup>[144]</sup> 提出的 DeepVID 系统采用知识蒸馏方法, 围绕用户感兴趣的数据训练局部变分自编码器, 以学习目标模型在感兴趣区域内的表现. 训练得到的局部模型作为局部代理模型, 可有效帮助对目标模型局部行为的理解. Ming 等<sup>[145]</sup> 提出了 RuleMatrix, 它将目标预测模型转换为基于规则的可解释的表达, 用来解释和探索目标模型的决策行为. 针对深度学习模型中的区域划分带来的结果波动, Zeng 等<sup>[146]</sup> 设计了可视分析系统, 以分析不同区域大小带来的影响.

在深度学习可视分析设计的实践中, 大部分工作综合了以上的多种方法, 以支持多样的分析任务. 例如 Bilal 等<sup>[105]</sup> 采用混淆矩阵以帮助发现分类错误图像, 采用热力图矩阵以观察各神经元对选定图像的反应, 结合类别的层次结构, 分析卷积神经网络是否学习到类别之间的层次化相似结构, 并支持对模型的理解和诊断. Pezzotti 等<sup>[147]</sup> 提出的 DeepEyes 系统, 通过观察模型的总体性能、每一层的性能、神经元的总体表现以及神经元之间的相似性, 删除退化的或不必要的层和神经元, 帮助优化模型结构. Wang 等<sup>[148]</sup> 设计了解释符号 – 概念关联网络的 SCANViz 系统. 该可视分析系统对模型的质量度量、模型的中间参数、训练数据、模型的隐空间进行可视化, 以支持模型的评估、隐空间探索和交互式训练. Cashman 等<sup>[149]</sup> 设计了 REMAP 系统, 以支持对庞大的模型结构和参数空间进行探索, 寻找合适的模型结构. 对于概念漂移现象, Wang 等<sup>[150]</sup> 和 Yang 等<sup>[151]</sup> 分别开发了可视分析系统, 从数据和模型的角度帮助理解和解释概念漂移.

针对各类具体的深度学习模型, 研究者开发了系列专用可视分析系统. 循环神经网络可视分析的工作包括 Strobelt 等<sup>[152]</sup> 提出的 LSTMVis 系统, Cashman 等<sup>[153]</sup> 提出的 RNNbow 系统和 Kwon 等<sup>[6]</sup> 提出的用于探索电子病历数据的 RetainVis 系统. 类似地, Strobelt 等<sup>[154]</sup> 针对由两个 RNN 结构组成的 seq2seq 模型设计了可视分析系统, 以支持交互式的探索和诊断. 深度强化学习模型中的输入状态和输出决策都是动态高维向量, 输入环境往往是三维环境, 其理解较一般模型更为困难. 为此, Jaunet 等<sup>[155]</sup>、Wang 等<sup>[156]</sup> 和 He 等<sup>[7]</sup> 分别设计了可视分析模型, 对智能体的决策、轨迹和视野内容、模型的记忆、奖励序列等内容进行分析. 生成对抗网络包括了生成模型和判别模型, Wang 等<sup>[157]</sup> 设计了可视分析系统 GANViz, 以深入理解其对抗训练过程.

### 3 人工智能驱动的可视化技术

在获得可视化的助力的同时, 人工智能技术也反过来促进了可视化技术的发展. 如图 1 所示, 人工智能技术与可视分析的各个阶段融合, 推动了智能可视化的发展. 本节从智能特征提取、可视化自动布局与生成、智能交互以及智能故事叙述 4 个方面论述人工智能驱动的可视化技术, 并且在每个小节中从技术层面和可视分析应用层面进行探讨.

#### 3.1 智能特征提取

人工智能技术支持对复杂特征的提取, 支持复杂模式的可视化, 具体内容包括可视特征提取、表示学习以及可视化元数据化等 3 种类型的方法.

##### 3.1.1 可视特征提取

在高维数据可视化中, Fujiwara 等<sup>[158]</sup> 提出了一种增量式降维方法. 其通过增强现有的增量式主

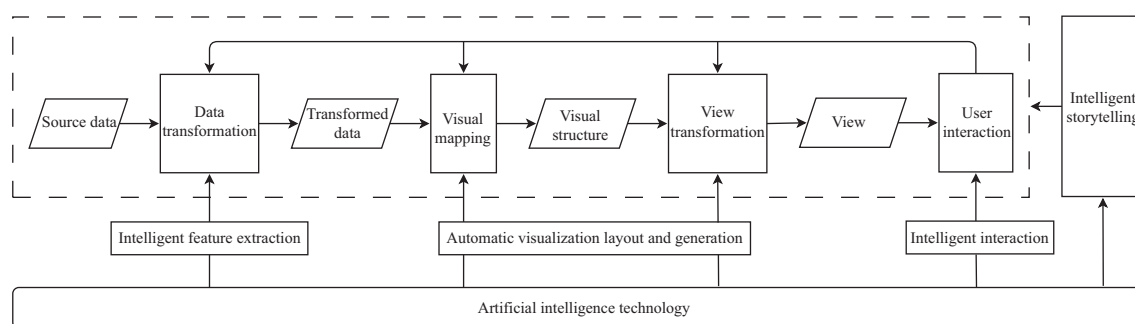


图 1 人工智能驱动的可视化技术, 包括智能特征提取、可视化自动布局与生成、智能交互和智能故事叙述

**Figure 1** Visualization techniques driven by artificial intelligence, including intelligent feature extraction, automatic visualization layout and generating, intelligent interaction, and intelligent storytelling

成分分析 (principal component analysis, PCA) 方法, 实现了流数据的快速降维可视化. Gortler 等<sup>[159]</sup> 提出了一个基于概率分布的 PCA 技术, 即在计算协方差矩阵时引入数据的第一和第二矩. 该方法可以看作 PCA 在多变量概率分布上的推广.

除了 PCA, 一些聚类技术也支持用户交互地抽取特征, 例如 Watanabe 等<sup>[160]</sup> 提出了一种结合双聚类技术从多变量数据中提取特征子空间的方法. 其可将高度相关的维度自动分组形成子空间, 并支持对子空间的进一步探索. Liu 等<sup>[161]</sup> 提出了一种基于子空间分析和动态投影的高维数据可视化交互探索框架, 其可从子空间聚类中提取每个子空间的内在维度并发现隐藏的模式.

Wang 等<sup>[162]</sup> 提出监督的降维方法, 以达到视觉上类别最大分离效果. Xia 等<sup>[9]</sup> 提出支持高维数据中低维结构探索与理解的降维方法, 构建投影视图, 支持分析高维数据的潜在局部结构. Zhou 等<sup>[163]</sup> 提出了一种方法, 使用户能够从多维数据子空间聚类结果中重建新的维度, 并保留聚类信息. 重构后的维度与原始维度一起被纳入到分析工作流中, 以帮助用户探索子空间.

### 3.1.2 表示学习

近年来由于深度学习在表示学习上的优异表现, 可视化领域开始利用深度学习等技术进行特征提取, 以创建具有语义信息的探索空间或可视化视图. 例如 Zhou 等<sup>[164]</sup> 将起讫点 (origin-destination, OD) 数据嵌入到高维空间, 利用 Word2Vec 模型获得了 OD 轨迹的表示向量, 支持后续的分析以得到更好的采样效果. Chen 等<sup>[10]</sup> 采用图向量化技术, 以支持子图结构的近似查询. Zhu 等<sup>[165]</sup> 将人流轨迹嵌入到高维空间, 得到了城市的语义化表达.

Xie 等<sup>[166]</sup> 将多视图表征引入多维数据探索. 他们首次提出子集表征模型, 将子集特征看作由一个虚拟的照相机从不同角度围绕子集拍摄的照片 (请参考文献 [166] 中的图 3 和 4). 通过子集表征, 可以同时生成大量不同形状子集, 并将它们一起投影, 用户可以在潜空间中准确高效地找到潜在的数据模式.

### 3.1.3 可视化元数据化

将可视化进行元数据化是近年来一个重要的趋势. 元数据化将可视化视图视为数据, 从可视化视图中提取特征, 用于探索可视化视图空间、理解视图语义等. 通过元数据化, 可以支持一系列的可视化特征提取、分类与生成. Kwon 等<sup>[167]</sup> 针对大图布局问题, 通过基于 GNN 的 VAE 模型训练得到图布局的表征空间, 以支持具有语义信息的探索. Ma 等<sup>[168]</sup> 提出了 ScatterNet, 使用 CNN 来提取散点图的语义特征进而计算散点图的相似度. Jäckle 等<sup>[169]</sup> 提出了基于时间的多维标度分析算法, 其可计算

随时间变化的多变量数据在时间上的一维多维标度分析图, 实现模式的可视化识别. Jo 等<sup>[11]</sup>提出了一种数据驱动的方法来获取散点图图像中的数据分布的可解释性表征. 其利用自编码器探寻表征的高级语义并促进用户对数据分布的理解. Haehn 等<sup>[170]</sup>则测评了 CNN 在不同可视化任务上的图形感知能力, 以促进 CNN 在应用于数据可视化时对感知能力和模型选择的理解.

### 3.1.4 特征提取的应用场景

在科学可视化方面, Krueger 等<sup>[171]</sup>提出的 Facetto 是一个可扩展的可视分析应用程序, 它实现了细胞类型和状态的半自动化分析. 该工作将无监督学习和监督学习集成到图像和特征探索过程中, 领域专家可以对数据进行聚类, 发现新的癌症和免疫细胞类型, 并利用聚类结果训练卷积神经网络, 进而对新细胞进行相应的分类. Han 等<sup>[172]</sup>提出的 FlowNet, 是一种可用于流线和流面聚类、筛选的深度学习模型, 其将特征学习、投影和探索过程整合到一个可视分析框架中. 与传统方法的全自动方式不同, FlowNet 的可视化界面使用户能够自定义其认为重要的代表性流线或流面, 使用户能够有效地探索流线和流面集.

在文本可视分析方面, Berger 等<sup>[173]</sup>提出了一个可视化方案 cite2vec, 它允许用户通过引文的使用情况动态地探索和浏览文档, 其通过将引文处的上下文语义编码至二维表征向量获取这些信息. 在时空可视分析领域, Tkachev 等<sup>[174]</sup>提出了一种基于机器学习的方法, 通过量化模型在局部行为预测上的预测误差, 检测并可视化时空数据中的异常. 在疾病和科学领域, Maljovec 等<sup>[175]</sup>设计了一个框架, 利用回归模型对多维核模拟数据进行灵敏度分析和可视化, 并将核反应堆敏感性信息传达给核科学家.

## 3.2 可视化自动布局与生成

### 3.2.1 端到端可视化生成

如图 1 所示, 人工智能技术作用于视觉映射和视图转换阶段, 促进了可视化自动布局与生成的发展. 一个常见的方向是根据给定的输入数据自动生成最佳的揭示数据内部模式的可视化. 模型的作用是拟合数据特征和可视编码之间的关系. 代表性的工作包括 Data2Vis<sup>[12]</sup>, VizML<sup>[13]</sup>, DiVE<sup>[176]</sup>, REACT<sup>[177]</sup>和 GenerativeMap<sup>[178]</sup>等. 在科学可视化方面, Berger 等<sup>[179]</sup>提出了一种使用生成模型来生成和分析体数据渲染图像的技术, 通过将视角、不透明度和颜色作为输入, 模型能够合成体数据渲染图像. Kim 等<sup>[180]</sup>利用 CNN 为给定的非稳定的二维矢量场提取一个近稳态参考帧. 其利用 CNN 进行滤波和特征提取, 并进行端到端的可视化以提升近稳态参考帧计算的速度. 这类技术的局限主要在于有限的训练集. Guo 等<sup>[181]</sup>提出了 SSR-VFD, 一种用于生成三维高分辨率矢量场可视化的方法. 其利用 CNN 及 GAN 从低分辨率向量场生成高分辨率向量场. Zhang 等<sup>[182]</sup>提出采用深度学习方法将信息嵌入到信息图中. Ge 等<sup>[183]</sup>提出了支持数据驱动的可视化图表动画的语言, 有效地支持端到端的可视化动画生成. 针对可视化图表中的颜色自动选择问题, Wang 等<sup>[184]</sup>提出了一种针对多类散点图的颜色自动分配方法, 该方法通过最大化类别间的可辨别性优化多类散点图的感知. 但该方法仅限于散点图且需要用户选择一个合适的调色板, 为此, Lu 等<sup>[185]</sup>提出了一个数据感知的调色板生成框架 Palettaylor, Palettaylor 可以自动为不同的可视化类型生成具有最大辨别性的分类调色板.

### 3.2.2 智能可视化布局

在图布局中, Zheng 等<sup>[186]</sup>提出了一种算法, 其使用随机梯度下降来最小化力导向图数据绘制中的能量函数, 从而更快更稳定地得到约束布局. Wakita 等<sup>[187]</sup>提出了一种高维旋转技术以避免大型

社交图可视化时的密集而不清晰的结构,通过对社交图进行高维嵌入,其允许用户拖动顶点来旋转高维空间中的社交图布局. Zhu 等<sup>[15]</sup>提出了一种基于降维的大规模图布局方法,提高了布局的可扩展性. 排序也是一种特殊的布局,在自动排序方面, Weng 等<sup>[188]</sup>提出了一种新型的空间排名可视化技术,用于探索和分析海量排名数据集. 通过对数据合适的筛选,该技术可以支持可扩展的智能可视化布局<sup>[189~193]</sup>.

### 3.2.3 高效可视化布局

另一个研究方向是加速超大规模数据集可视化. 超大规模的数据可视化的生成往往非常耗时,很难支持可视化的交互操作. 这类技术的核心是训练模型作为可视化生成器. 模型以用户交互为输入,不经过数据查询和处理,直接输出可视化,从而避免耗时的数据操作和数据计算. He 等<sup>[14]</sup>提出了 InSituNet,从超级计算机进行的科学仿真模拟中获得训练集,并进行离线的端到端模型训练,由模型直接接收用户的可视化设置及科学仿真参数,生成新的图像,从而加速可视化的构建. Wang 等<sup>[194]</sup>提出的 DeepOrganNet,采用类似的思路构建了支持人体器官探索的可视化模型. 不同于之前技术的模型直接输出可视化, Hu 等<sup>[195]</sup>训练模型进行数据采用,通过压缩参与可视化的数据量,在保持可视化特征前提下实现大规模数据可视化. 在词云的布局中, Wang 等<sup>[196]</sup>提出的 ShapeWordle,利用词云构造技术,支持形状约束的词云快速有效构建.

### 3.2.4 自动可视化布局与生成的应用场景

在应用领域,人工智能技术常被用来加速基于图的布局与分析算法. 这些工作的主要思路是首先利用 AI 模型构建图结构的投影空间,之后开发交互式可视化系统支持用户在投影空间中交互探索,完成相似查询、因果推理等任务. Bae 等<sup>[197]</sup>采用该模式探索了最适合揭示因果关系的图布局. Bhowmick 等<sup>[198]</sup>提出了一个名为 AURORA 的交互式子图查询工具. Song 等<sup>[199]</sup>设计了 Boomer 系统以提高图数据库的可用性. 对于文本与标签的可视化布局, Meng 等<sup>[200]</sup>提出了一种上下文感知的标签布局,可以在布局过程中测量和减少视觉杂乱,帮助用户在标签数量较多时快速获得数据概况. Chen 等<sup>[201]</sup>对历年 IEEE VAST 论文中的多视图可视化设计数据进行了搜集和整理,为后续的自动化设计与布局研究提供了数据集.

## 3.3 智能交互

### 3.3.1 交互对象选择

在复杂可视化场景中交互地选择数据对象一直是可视化领域的一个研究难点. 杂乱的布局、对象之间的互相遮挡等问题对于实时判断对象是否在选择范围内带来了较大的挑战. 为了解决大数据量对交互操作的影响,很多研究人员尝试训练 AI 模型加速交互操作,提高交互效率. Fan 等<sup>[202]</sup>提出了一种基于 CNN 的散点图刷选方法,其利用 CNN 从刷选操作以及可视化的数据分布中预测用户刷选的数据点,从而加速刷选操作的流畅性并将误差率控制在较低水平. Chen 等<sup>[203]</sup>提出了 LassoNet,以优化 3D 点云的套索选择. Yang 等<sup>[16]</sup>针对体数据渲染中智能视角选择问题,提出了基于深度学习的解决方案. 这类研究工作还不多,目前只有少数研究组在开展相关研究. 如何避免模型预测偏差并提高对象选择准确性是目前研究的重点.

### 3.3.2 交互数据探索

从多维数据集中交互地寻找数据模式是一个耗时的过程. 在没有辅助的情况下,用户需要不停地

修改探索设置, 庞大的搜索空间为数据探索带来了很大的障碍。很多研究工作尝试训练 AI 模型来辅助数据探索。通过推荐参数设置等方式引导用户快速找到数据中存在的模式。Ottley 等<sup>[204]</sup>从用户的上一步交互探索中提取用户注意力, 从而实现对用户未来交互动作的准确预测。Savvides 等<sup>[205]</sup>训练 AI 模型引导用户的交互操作。Gao 等<sup>[206]</sup>提出了一个模型推荐方法, 根据系统作出的反馈, 自动调用最匹配的模式。

另一类研究工作训练 AI 模型来作为某个复杂分析对象的代理。AI 模型可以接受用户的输入, 并预测被代理的分析对象的状态。这类工作为分析复杂对象带来了一个新的思路。He 等<sup>[14]</sup>提出了 InSituNet 作为复杂科学模型集成的代理, 当用户输入某个参数时, 该模型可以直接预测大规模科学模型集成的输出结果 (请参考文献 [14] 中的图 7)。Hazarika 等<sup>[207]</sup>提出了 NNVA 模型作为生物细胞的代理, 该模型可以跳过耗时的仿真计算并快速输出任何细胞操作的应激效果。

### 3.3.3 交互可视查询

交互式可视化系统往往需要在可接受的响应时间内生成满足用户查询条件的可视化。当查询结果涉及大量数据时, 快速生成其可视化往往是很困难的, 传统上这类技术总是使用基于数据预存储的策略, 但庞大的存储开销使得这类技术需要巨大的存储开销。深度学习为这类技术带来了一个可行的解决方案。我们可以训练深度学习模型拟合用户查询和输出可视化之间的关系, 这样当用户执行某个交互操作之后, 可以跳过耗时的数据遍历直接输出可视化, 从而满足实时查询的需要。Zhang 等<sup>[208]</sup>提出了 TARDIS 来支持亿级数据的索引和可视化查询。Hong 等<sup>[209]</sup>提出了 DNN-VolVis, 使用神经网络获得目标在新视角下的渲染结果。Huang 等<sup>[210]</sup>提出了基于自然语言的可视查询方法。Wang 等<sup>[211]</sup>提出了 Gaussian Cubes, 支持交互查询大规模数据的分布与统计图。其他类似工作还包括 RSATree<sup>[212]</sup>, SmartCube<sup>[213]</sup>, Marviq<sup>[214]</sup> 和 BigIN4<sup>[215]</sup> 等。Li 等<sup>[216]</sup>提出了语义立方体, 以支持交互地在语义层面分析大规模时空文本。

### 3.3.4 交互数据分析

智能交互在多个领域的可视分析中得到了广泛的使用。针对文本数据, El-Assady 等<sup>[217]</sup>提出了 NEREx, 一个交互式谈话内容语义分析工具, 该工作结合可视化和自然语言模型分析大规模文本的语义信息。El-Assady 等<sup>[218]</sup>提出了结合领域知识的主题模型, 并设计了一个可视化工具允许用户交互地编辑主题。Guo 等<sup>[219]</sup>提出了 ThoughtFlow, 该工具支持探索科学文献之间的关系, Sperrle 等<sup>[61]</sup>提出了一个可视分析系统, 从用户交互中学习论点相似性的测量方法。Leventidis 等<sup>[220]</sup>提出一种方法自动将 SQL 查询语句转化为清晰的视图, 提高分析人员理解 SQL 语句的速度。Xu 等<sup>[221]</sup>提出了一种基于协同聚类方法的交互式可视化设计, 用以识别二部图中的节点簇。Snyder 等<sup>[63]</sup>提出了一种智能方法可以交互感知社交媒体态势。Wu 等<sup>[222]</sup>利用 AI 技术交互分析和编辑语音识别结果。

## 3.4 智能故事叙述

故事叙述 (storytelling) 作为可视化领域的新兴方向, 也结合了人工智能领域的最新研究成果。故事叙述是指把在很多视图中发现的碎片化的模式, 根据其内部的联系, 梳理成具有完整故事脉络的整体, 以帮助人更好地理解相关事件发展的全流程。AI 技术在故事叙述中主要起到信息补全、语义挖掘、关系抽取等作用。

Cui 等<sup>[223]</sup>提出了从自然语言中自动生成信息图的可视分析方法, 也是一种端到端的可视化生成, 用于故事叙述。Wang 等<sup>[224]</sup>提出了 DataShot, 确定了常见的信息图结构、工作表布局、事件类型和

可视化风格,并基于这些发现提出了一个事件表生成流水线.Zeng等<sup>[225]</sup>提出了EmoCo,用于高效分析演示视频中跨面部、文字和音频模式的情感连贯性,使用户能够快速获得情感连贯性及其时间演变的概述.Shi等<sup>[226]</sup>利用自然语言处理技术从多人会话中提取交流主题和故事线索,并用Storyline呈现多人会话进程.Tang等<sup>[227]</sup>提出了iStoryline,该工具集成了智能布局算法以支持故事线的绘制.

Lai等<sup>[228]</sup>提出了可视化动画自动生成方案.基于用户输入的可视化图像和自然语言描述,模型可自动生成带高亮与注释的动画以辅助故事叙述.Liu等<sup>[229]</sup>提出了AutoCaption,以自动为可视化生成自然语言描述.Wang等<sup>[230]</sup>提出了一种新型的基于图的视觉故事架构.Chen等<sup>[231]</sup>提出了一套将可视分析结果导入故事叙述的框架方法,从理论上讨论了从复杂的分析结果到让人易懂的故事叙述,在目标用户、分析对象和呈现方法上的异同,指导用户快速将可视分析的结果半自动地生成故事叙述的可视化结果.

Yang等<sup>[232]</sup>提出了一种常识驱动的生成模型,旨在从外部知识库中引入关键常识来进行视觉故事讲述.该技术不仅可以提取文本、表格中的事件,还可从图像、视频中进行事件的提取和故事的生成.Chen等<sup>[233]</sup>从位图中自动提取时间线以重构和解析故事脉络.Jung等<sup>[234]</sup>设计了一个基于RNN的模型以实现缺失情节的补全.Hu等<sup>[235]</sup>分析了什么是好的故事叙述,并给出了评估故事叙述质量的标准.基于此,他们提出一个强化学习框架支持寻找高质量故事叙述.Fulda等<sup>[236]</sup>提出了TimeLineCurator,其可以使用自然语言处理从非结构化文本文档的时间引用中自动提取事件数据,并将事件以时间线的形式进行可视化.

## 4 发展趋势与展望

目前,可视化与人工智能的交叉研究已经表现出了巨大的潜力,促进了可视化与人工智能领域的关键技术发展.在如下方面,可视化与人工智能的交叉研究有望取得较大突破.

(1) 协同可视分析中的数据隐私保护.数据分布在多个数据拥有方,是大数据应用场景中的常态,自然产生了多方参与的协同可视分析任务.然而,由于数据版权或隐私保护问题,这些数据拥有方往往无法直接共享数据.协同可视分析有两项关键挑战.首先,如何在互不交互数据的情况下生成联合数据可视化结果.其次,数据可视化结果如何保护数据隐私.目前,对于第一个问题的研究还较少.安全多方计算、联邦学习等方法为解决数据孤岛问题提供了思路.如何将 these 方法应用于协同数据可视分析,是值得研究的方向.

(2) 可解释机器学习.首先,目前的大部分研究聚焦于模型训练后的离线分析.但深度学习模型的训练本身是一个耗时的过程,随着深度学习模型规模和训练数据量的进一步增长,训练时长已增加到数天甚至数周.及时发现训练过程中的偏差并进行诊断和决策具有重要的意义.类似地,在在线学习过程中,训练过程随着流数据的到来持续进行,离线分析模式往往难以及时捕捉数据和模型的变化,从而无法提供有效的指导.研究深度学习的在线可视分析方法,在训练过程中对模型进行监督和指导,具有重要的研究意义.

其次,目前大部分的可视分析系统针对特定模型进行定制,难以与深度学习框架进行融合.各个可视分析系统之间的区别较大,尚未形成统一的方法体系.而现有的深度学习框架平台上,仅集成了轻量级的可视化组件,难以支持深入全面的分析.研究与主流深度学习框架集成的可视分析架构,打造可解释机器学习系统生态,有利于可视分析的研究成果在人工智能领域的普及,也有利于基于可视化的可解释机器学习的统一理论的总结与提炼.从自有知识产权的角度出发,应考虑在计图(Jittor)<sup>[237]</sup>等国产框架上的集成研发.

(3) 智能特征提取. 人工智能的进展改变了特征提取的流程, 减少了特征工程的工作量, 通过端到端的形式提供数据的压缩表达. 另一方面, 人工智能提供了多种嵌入方法, 将复杂类型数据转换到易于理解的高维空间. 因此, 基于人工智能的特征提取为可视化与可视分析提供了简洁的表达基础. 用于可视化与可视分析的特征提取面临的挑战在于: 自动提取的特征不一定具有明确的语义信息, 不利于理解与解释. 如何根据分析需求定制语义特征提取方法, 是当前需要解决的难题.

(4) 可视化的自动生成. 自动可视化从数据自动生成能够准确表达重要模式的可视化视图, 对缺乏相关知识和技能的普通用户具有重要的作用. 当前主要有两类方法. 第 1 类是基于设计经验知识, 将可视化设计问题归约成最优化问题求解. 这一类方法效果较好, 具有较高的可理解性. 但最优化原则的提炼需要较多的设计经验和尝试. 第 2 类方法是采用具有端到端性质的深度学习, 跳过了对设计原则的总结阶段. 当前, 在大图的布局、大规模数据体绘制等算法上, 深度学习模型取得了良好的效果. 但由于数据空间和可视化视图空间都非常庞大, 训练深度学习模型需要大量的高质量训练数据. 对于大多数可视化视图而言, 训练数据集的生成是一个需要攻克的难题.

在可视分析系统设计方面, 当前的可视分析系统大多遵循“需求分析 – 数据抽象 – 可视编码 – 算法实现 – 迭代改进”的研发路线, 进行“一事一议”式的定制化开发. 尽管具有可视编码、分析策略等方面的理论指导, 但整个设计过程具有较多的个性化和主观性. 一套设计好的系统, 如何扩展到其他领域、其他数据集, 甚至合作领域户外的使用者上, 尚无理论总结. 如何评价可视分析系统的认知效率和分析效率, 也缺乏明确的理论指导. 如何从设计实践中归纳和总结, 形成统一、标准化的可视分析设计理论, 是可视分析领域最重要的科学问题之一. 人工智能技术的发展为可视分析设计理论研究带来了新的契机. 经过多年的实践, 可视分析领域已经积累了大量的可视分析系统和使用记录. 采用数据驱动的思想, 对各类编码、布局、交互技术进行总结和重新审视, 对可视分析系统的效率进行评估, 具有重要的研究意义.

(5) 智能交互. 人机交互是可视分析中不可或缺的一环, 目前的挑战主要包括两个方面. 首先是精确的选择. 如何在全体数据集中精确地选取包含感兴趣模式的子集, 是当前研究的热点问题, 例如在点云数据中选取感兴趣部分, 在时空数据中选取保护特定模式的时间段. 其次是大规模数据的交互难题. 由于存储和计算方面的压力, 大规模数据的交互一直是一个挑战. 人工智能技术通过压缩表达、智能索引、查询预测等方法, 为解决交互难题提供了技术途径. 如何提出准确、普适的智能交互方法, 将是未来研究的重点.

(6) 智能故事叙述. 可视化的核心功能是信息的表达, 如何用可视化讲好一个故事, 是可视化研究的重要主题. 随着人工智能技术的发展, 利用可视化进行故事叙述的研究进一步变为智能故事叙述. 具体而言, 智能故事叙述主要体现在以下方面: 首先, 是故事的自动拆解与自动化生成. 会有更多的研究致力于提炼故事叙述的元素、将组成故事的可视化表达进行拆解与总结, 进一步地支持故事的自动化生成. 其次, 在自动化的基础上, 智能故事叙述的第二个体现是多样性, 智能的意义在于可以学习不同的故事风格、叙述手法、可视化表达, 进行组合与创造, 产生新的多种多样的可视化故事叙述. 最后是人机融合, 用户可以用极小的交互代价, 利用机器智能构造出符合用户心中构思的故事的样子, 即在多样的故事中能够快速智能地构造出符合用户预期的可视化故事.

## 5 结束语

本文对人工智能与可视化的交叉研究这一研究热点进行了较为全面的总结. 从面向人工智能的可视化与可视分析的角度, 对数据质量改善、基于可视化的可解释机器学习进行了分析. 从人工智能驱



动的可视化技术的角度,对表示学习与特征提取、可视化自动布局与生成、智能交互、智能故事叙述进行了总结。我们重点概述了2017年以来近3年的国内外研究工作,并对国内外研究现状进行了分析,对发展趋势进行了展望。人工智能与可视化的交叉研究仍然处于起步阶段,还存在很大的发展空间。希望本文能够帮助读者对“AI+VIS”的研究建立较为全面的认识,并对今后的相关工作起到启发作用。

## 参考文献

- 1 Yuan J, Chen C, Yang W, et al. A survey of visual analytics techniques for machine learning. *Comp Visual Media*, 2021, 7: 3–36
- 2 Fan X, Li C, Yuan X, et al. An interactive visual analytics approach for network anomaly detection through smart labeling. *J Vis*, 2019, 22: 955–971
- 3 Chen C, Yuan J, Lu Y, et al. OoDAnalyzer: interactive analysis of out-of-distribution samples. *IEEE Trans Visual Comput Graph*, 2021, 27: 3335–3349
- 4 Bäuerle A, Neumann H, Ropinski T. Classifier-guided visual correction of noisy labels for image classification tasks. *Comput Graph Forum*, 2020, 39: 195–205
- 5 Castelvechi D. Can we open the black box of AI? *Nature*, 2016, 538: 20–23
- 6 Kwon B C, Choi M J, Kim J T, et al. RetainVis: visual analytics with interpretable and interactive recurrent neural networks on electronic medical records. *IEEE Trans Visual Comput Graph*, 2019, 25: 299–309
- 7 He W, Lee T Y, van Baar J, et al. DynamicsExplorer: visual analytics for robot control tasks involving dynamics and LSTM-based control policies. In: *Proceedings of the IEEE Pacific Visualization Symposium*, 2020. 36–45
- 8 Ming Y, Cao S, Zhang R, et al. Understanding hidden memories of recurrent neural networks. In: *Proceedings of the IEEE Conference on Visual Analytics Science and Technology*, 2017. 13–24
- 9 Xia J, Ye F, Chen W, et al. LDSScanner: exploratory analysis of low-dimensional structures in high-dimensional datasets. *IEEE Trans Visual Comput Graph*, 2018, 24: 236–245
- 10 Chen W, Guo F, Han D, et al. Structure-based suggestive exploration: a new approach for effective exploration of large networks. *IEEE Trans Visual Comput Graph*, 2019, 25: 555–565
- 11 Jo J, Seo J. Disentangled representation of data distributions in scatterplots. In: *Proceedings of the IEEE Visualization Conference*, 2019. 136–140
- 12 Dibia V, Demiralp C. Data2Vis: automatic generation of data visualizations using sequence-to-sequence recurrent neural networks. *IEEE Comput Graph Appl*, 2019, 39: 33–46
- 13 Hu K, Bakker M A, Li S, et al. VizML: a machine learning approach to visualization recommendation. In: *Proceedings of the CHI Conference on Human Factors in Computing Systems*, 2019. 1–12
- 14 He W, Wang J, Guo H, et al. InSituNet: deep image synthesis for parameter space exploration of ensemble simulations. *IEEE Trans Visual Comput Graph*, 2020, 26: 23–33
- 15 Zhu M, Chen W, Hu Y, et al. DRGraph: an efficient graph layout algorithm for large-scale graphs by dimensionality reduction. *IEEE Trans Visual Comput Graph*, 2021, 27: 1666–1676
- 16 Yang C, Li Y, Liu C, et al. Deep learning-based viewpoint recommendation in volume visualization. *J Vis*, 2019, 22: 991–1003
- 17 Tan S, Bhowmick S S, Chua H E, et al. LATTE: visual construction of smart contracts. In: *Proceedings of the ACM SIGMOD International Conference on Management of Data*, 2020. 2713–2716
- 18 Liu S, Wang X, Liu M, et al. Towards better analysis of machine learning models: a visual analytics perspective. *Visual Inf*, 2017, 1: 48–56
- 19 Hohman F, Kahng M, Pienta R, et al. Visual analytics in deep learning: an interrogative survey for the next frontiers. *IEEE Trans Visual Comput Graph*, 2019, 25: 2674–2693
- 20 Zhang Q, Zhu S. Visual interpretability for deep learning: a survey. *Front Inf Technol Electron Eng*, 2018, 19: 27–39
- 21 Sacha D, Kraus M, Keim D A, et al. VIS4ML: an ontology for visual analytics assisted machine learning. *IEEE Trans Visual Comput Graph*, 2019, 25: 385–395
- 22 Taleb I, Serhani M A, Dssouli R. Big data quality: a survey. In: *Proceedings of the IEEE International Congress on*

- Big Data, 2018. 166–173
- 23 von Zernichow B M, Roman D. Usability of visual data profiling in data cleaning and transformation. In: Proceedings of the OTM Confederated International Conferences On the Move to Meaningful Internet Systems, 2017. 480–496
- 24 Liu S, Andrienko G, Wu Y, et al. Steering data quality with visual analytics: the complexity challenge. Visual Inf, 2018, 2: 191–197
- 25 Oliveira P, Rodrigues F, Henriques P R. A formal definition of data quality problems. In: Proceedings of the ICIQ, 2005
- 26 Sidi F, Panahy P H S, Affendey L S, et al. Data quality: a survey of data quality dimensions. In: Proceedings of the International Conference on Information Retrieval & Knowledge Management, 2012. 300–304
- 27 Chandola V, Banerjee A, Kumar V. Anomaly detection: a survey. ACM Comput Surv, 2009, 41: 1–58
- 28 Butscher S, Hubenschmid S, Müller J, et al. Clusters, trends, and outliers: how immersive technologies can facilitate the collaborative analysis of multidimensional data. In: Proceedings of the CHI Conference on Human Factors in Computing Systems, 2018. 1–12
- 29 Wilkinson L. Visualizing big data outliers through distributed aggregation. IEEE Trans Visual Comput Graph, 2018, 24: 256–266
- 30 Cao N, Lin Y R, Gotz D, et al. Z-Glyph: visualizing outliers in multivariate data. Inf Vis, 2018, 17: 22–40
- 31 Xu K, Xia M, Mu X, et al. EnsembleLens: ensemble-based visual exploration of anomaly detection algorithms with multidimensional data. IEEE Trans Visual Comput Graph, 2019, 25: 109–119
- 32 Zhao X, Cui W, Wu Y, et al. Oui! Outlier interpretation on multi-dimensional data via visual analytics. Comput Graph Forum, 2019, 38: 213–224
- 33 Gschwandtner T, Erhart O. Know your enemy: identifying quality problems of time series data. In: Proceedings of the IEEE Pacific Visualization Symposium, 2018. 205–214
- 34 Tao J, Shi L, Zhuang Z, et al. Visual analysis of collective anomalies through high-order correlation graph. In: Proceedings of the IEEE Pacific Visualization Symposium, 2018. 150–159
- 35 Xie C, Xu W, Mueller K. A visual analytics framework for the detection of anomalous call stack trees in high performance computing applications. IEEE Trans Visual Comput Graph, 2019, 25: 215–224
- 36 Bögl M, Filzmoser P, Gschwandtner T, et al. Cycle plot revisited: multivariate outlier detection using a distance-based abstraction. Comput Graph Forum, 2017, 36: 227–238
- 37 Arbesser C, Spechtenhauser F, Muhlbacher T, et al. Visplause: visual data quality assessment of many time series using plausibility checks. IEEE Trans Visual Comput Graph, 2017, 23: 641–650
- 38 Dixit P M, Suriadi S, Andrews R, et al. Detection and interactive repair of event ordering imperfection in process logs. In: Proceedings of the International Conference on Advanced Information Systems Engineering, 2018. 274–290
- 39 Goodall J R, Ragan E D, Steed C A, et al. Situ: identifying and explaining suspicious behavior in networks. IEEE Trans Visual Comput Graph, 2019, 25: 204–214
- 40 Song H, Szafr D A. Where's my data? Evaluating visualizations with missing data. IEEE Trans Visual Comput Graph, 2019, 25: 914–924
- 41 Xu K, Wang Y, Yang L, et al. CloudDet: interactive visual analysis of anomalous performances in cloud computing systems. IEEE Trans Visual Comput Graph, 2020, 26: 1107–1117
- 42 Mu X, Xu K, Chen Q, et al. MOOCad: visual analysis of anomalous learning activities in massive open online courses. In: Proceedings of the EuroVis, 2019. 91–95
- 43 Wu W, Zheng Y, Chen K, et al. A visual analytics approach for equipment condition monitoring in smart factories of process industry. In: Proceedings of the IEEE Pacific Visualization Symposium, 2018. 140–149
- 44 Xu K, Guo S, Cao N, et al. ECGLens: interactive visual exploration of large scale ECG data for arrhythmia detection. In: Proceedings of the CHI Conference on Human Factors in Computing Systems, 2018. 1–12
- 45 Zhao Y, Luo X, Lin X, et al. Visual analytics for electromagnetic situation awareness in radio monitoring and management. IEEE Trans Visual Comput Graph, 2020, 26: 590–600
- 46 Zhao Y, Wang L, Li S, et al. A visual analysis approach for understanding durability test data of automotive products. ACM Trans Intell Syst Technol, 2019, 10: 1–23
- 47 Zhao Y, Luo F, Chen M, et al. Evaluating multi-dimensional visualizations for understanding fuzzy clusters. IEEE Trans Visual Comput Graph, 2019, 25: 12–21

- 48 Cao N, Lin C, Zhu Q, et al. Voila: visual anomaly detection and monitoring with streaming spatiotemporal data. *IEEE Trans Visual Comput Graph*, 2018, 24: 23–33
- 49 Lin C, Zhu Q, Guo S, et al. Anomaly detection in spatiotemporal data via regularized non-negative tensor analysis. *Data Min Knowl Disc*, 2018, 32: 1056–1073
- 50 Shi Y, Xu M, Zhao R, et al. Interactive context-aware anomaly detection guided by user feedback. *IEEE Trans Human-Mach Syst*, 2019, 49: 550–559
- 51 Bernard J, Hutter M, Zeppelzauer M, et al. Comparing visual-interactive labeling with active learning: an experimental study. *IEEE Trans Visual Comput Graph*, 2018, 24: 298–308
- 52 Xiang S, Ye X, Xia J, et al. Interactive correction of mislabeled training data. In: *Proceedings of the IEEE Conference on Visual Analytics Science and Technology*, 2019. 57–68
- 53 Park J H, Nadeem S, Boorboor S, et al. CMed: crowd analytics for medical imaging data. *IEEE Trans Visual Comput Graph*, 2021, 27: 2869–2880
- 54 Liu S, Chen C, Lu Y, et al. An interactive method to improve crowdsourced annotations. *IEEE Trans Visual Comput Graph*, 2019, 25: 235–245
- 55 Kurzhals K, Hlawatsch M, Seeger C, et al. Visual analytics for mobile eye tracking. *IEEE Trans Visual Comput Graph*, 2017, 23: 301–310
- 56 Khayat M, Karimzadeh M, Zhao J, et al. VASSL: a visual analytics toolkit for social spambot labeling. *IEEE Trans Visual Comput Graph*, 2020, 26: 874–883
- 57 Halter G, Ballester-Ripoll R, Flueckiger B, et al. VIAN: a visual annotation tool for film analysis. *Comput Graph Forum*, 2019, 38: 119–129
- 58 de Rooij O, van Wijk J J, Worring M. MediaTable: interactive categorization of multimedia collections. *IEEE Comput Graph Appl*, 2010, 30: 42–51
- 59 Stein M, Janetzko H, Breikreutz T, et al. Director's cut: analysis and annotation of soccer matches. *IEEE Comput Graph Appl*, 2016, 36: 50–60
- 60 Bernard J, Zeppelzauer M, Sedlmair M, et al. VIAL: a unified process for visual interactive labeling. *Vis Comput*, 2018, 34: 1189–1207
- 61 Sperrle F, Sevastjanova R, Kehlbeck R, et al. Viana: visual interactive annotation of argumentation. In: *Proceedings of the IEEE Conference on Visual Analytics Science and Technology*, 2019. 11–22
- 62 Junior A S, Renso C, Matwin S. ANALYTIC: an active learning system for trajectory classification. *IEEE Comput Graph Appl*, 2017, 37: 28–39
- 63 Snyder L S, Lin Y S, Karimzadeh M, et al. Interactive learning for identifying relevant tweets to support real-time situational awareness. *IEEE Trans Visual Comput Graph*, 2020, 26: 558–568
- 64 Lekschas F, Peterson B, Haehn D, et al. Peax: interactive visual pattern search in sequential data using unsupervised deep representation learning. *Comput Graph Forum*, 2020, 39: 167–179
- 65 Bernard J, Zeppelzauer M, Lehmann M, et al. Towards user-centered active learning algorithms. *Comput Graph Forum*, 2018, 37: 121–132
- 66 Chang J C, Amershi S, Kamar E. Revolt: collaborative crowdsourcing for labeling machine learning datasets. In: *Proceedings of the CHI Conference on Human Factors in Computing Systems*, 2017. 2334–2346
- 67 Chou J K, Wang Y, Ma K L. Privacy preserving visualization: a study on event sequence data. *Comput Graph Forum*, 2019, 38: 340–355
- 68 Chou J K, Bryan C, Ma K L. Privacy preserving visualization for social network data with ontology information. In: *Proceedings of the IEEE Pacific Visualization Symposium*, 2017. 11–20
- 69 Chou J K, Bryan C, Li J, et al. An empirical study on perceptually masking privacy in graph visualizations. In: *Proceedings of the IEEE Symposium on Visualization for Cyber Security*, 2018. 1–8
- 70 Wang X, Chou J K, Chen W, et al. A utility-aware visual approach for anonymizing multi-attribute tabular data. *IEEE Trans Visual Comput Graph*, 2018, 24: 351–360
- 71 Wang X, Chen W, Chou J K, et al. GraphProtector: a visual interface for employing and assessing multiple privacy preserving graph algorithms. *IEEE Trans Visual Comput Graph*, 2019, 25: 193–203
- 72 Xia J, Chen T, Zhang L, et al. SMAP: a joint dimensionality reduction scheme for secure multi-party visualization. In: *Proceedings of the IEEE Conference on Visual Analytics Science and Technology*, 2020. 107–118

- 73 Sacha D, Sedlmair M, Zhang L, et al. What you see is what you can change: human-centered machine learning by interactive visualization. *Neurocomputing*, 2017, 268: 164–175
- 74 Miller T. Explanation in artificial intelligence: insights from the social sciences. *Artif Intell*, 2019, 267: 1–38
- 75 Chatzimpampas A, Martins R M, Jusufi I, et al. A survey of surveys on the use of visualization for interpreting machine learning models. *Inf Vis*, 2020, 19: 207–233
- 76 Wexler J, Pushkarna M, Bolukbasi T, et al. The what-if tool: interactive probing of machine learning models. *IEEE Trans Visual Comput Graph*, 2020, 26: 56–65
- 77 Hohman F, Head A, Caruana R, et al. Gamut: a design probe to understand how data scientists understand machine learning models. In: *Proceedings of the CHI Conference on Human Factors in Computing Systems*, 2019. 1–13
- 78 Spinner T, Schlegel U, Schafer H, et al. explainer: a visual analytics framework for interactive and explainable machine learning. *IEEE Trans Visual Comput Graph*, 2020, 26: 1064–1074
- 79 Cheng H F, Wang R, Zhang Z, et al. Explaining decision-making algorithms through UI: strategies to help non-expert stakeholders. In: *Proceedings of the CHI Conference on Human Factors in Computing Systems*, 2019. 1–12
- 80 Cabrera Á A, Epperson W, Hohman F, et al. Fairvis: visual analytics for discovering intersectional bias in machine learning. In: *Proceedings of the IEEE Conference on Visual Analytics Science and Technology*, 2019. 46–56
- 81 Ahn Y, Lin Y R. FairSight: visual analytics for fairness in decision making. *IEEE Trans Visual Comput Graph*, 2020, 26: 1086–1095
- 82 Yan J N, Gu Z, Lin H, et al. Silva: interactively assessing machine learning fairness using causality. In: *Proceedings of the CHI Conference on Human Factors in Computing Systems*, 2020. 1–13
- 83 Krause J, Dasgupta A, Swartz J, et al. A workflow for visual diagnostics of binary classifiers using instance-level explanations. In: *Proceedings of the IEEE Conference on Visual Analytics Science and Technology*, 2017. 162–172
- 84 Ma Y, Xie T, Li J, et al. Explaining vulnerabilities to adversarial machine learning through visual analytics. *IEEE Trans Visual Comput Graph*, 2020, 26: 1075–1085
- 85 Zhao X, Wu Y, Lee D L, et al. iForest: interpreting random forests via visual analytics. *IEEE Trans Visual Comput Graph*, 2019, 25: 407–416
- 86 Liu S, Xiao J, Liu J, et al. Visual diagnosis of tree boosting methods. *IEEE Trans Visual Comput Graph*, 2018, 24: 163–173
- 87 Ren D, Amershi S, Lee B, et al. Squares: supporting interactive performance analysis for multiclass classifiers. *IEEE Trans Visual Comput Graph*, 2017, 23: 61–70
- 88 Gleicher M, Barve A, Yu X, et al. Boxer: interactive comparison of classifier results. *Comput Graph Forum*, 2020, 39: 181–193
- 89 Cavallo M, Demiralp Ç. Track Xplorer: a system for visual analysis of sensor-based motor activity predictions. *Comput Graph Forum*, 2018, 37: 339–349
- 90 Mühlbacher T, Linhardt L, Möller T, et al. TreePOD: sensitivity-aware selection of pareto-optimal decision trees. *IEEE Trans Visual Comput Graph*, 2018, 24: 174–183
- 91 Dingen D, van't Veer M, Houthuizen P, et al. RegressionExplorer: interactive exploration of logistic regression models with subgroup analysis. *IEEE Trans Visual Comput Graph*, 2019, 25: 246–255
- 92 Das S, Cashman D, Chang R, et al. BEAMES: interactive multimodel steering, selection, and inspection for regression tasks. *IEEE Comput Graph Appl*, 2019, 39: 20–32
- 93 Zhang C, Yang J, Zhan F B, et al. A visual analytics approach to high-dimensional logistic regression modeling and its application to an environmental health study. In: *Proceedings of the IEEE Pacific Visualization Symposium*, 2016. 136–143
- 94 Cavallo M, Demiralp Ç. A visual interaction framework for dimensionality reduction based data exploration. In: *Proceedings of the CHI Conference on Human Factors in Computing Systems*, 2018. 1–13
- 95 Faust R, Glickenstein D, Scheidegger C. DimReader: axis lines that explain non-linear projections. *IEEE Trans Visual Comput Graph*, 2019, 25: 481–490
- 96 Kwon B C, Kim H, Wall E, et al. AxiSketcher: interactive nonlinear axis mapping of visualizations through user drawings. *IEEE Trans Visual Comput Graph*, 2017, 23: 221–230
- 97 Li Q, Njotoprawiro K S, Haleem H, et al. EmbeddingVis: a visual analytics approach to comparative network embedding inspection. In: *Proceedings of the IEEE Conference on Visual Analytics Science and Technology*, 2018.

- 48–59
- 98 Lu M, Wang S, Lanir J, et al. Winglets: visualizing association with uncertainty in multi-class scatterplots. *IEEE Trans Visual Comput Graph*, 2020, 26: 770–779
  - 99 Bian R, Xue Y, Zhou L, et al. Implicit multidimensional projection of local subspaces. *IEEE Trans Visual Comput Graph*, 2021, 27: 1558–1568
  - 100 Cavallo M, Demiralp Ç. Clustrophile 2: guided visual clustering analysis. *IEEE Trans Visual Comput Graph*, 2019, 25: 267–276
  - 101 Kwon B C, Eysenbach B, Verma J, et al. Clustervision: visual supervision of unsupervised clustering. *IEEE Trans Visual Comput Graph*, 2018, 24: 142–151
  - 102 Sacha D, Kraus M, Bernard J, et al. SOMFlow: guided exploratory cluster analysis with self-organizing maps and analytic provenance. *IEEE Trans Visual Comput Graph*, 2018, 24: 120–130
  - 103 Yang W, Wang X, Lu J, et al. Interactive steering of hierarchical clustering. *IEEE Trans Visual Comput Graph*, 2021, 27: 3953–3967
  - 104 Kwon B C, Anand V, Severson K A, et al. DPVis: visual analytics with hidden Markov models for disease progression pathways. *IEEE Trans Visual Comput Graph*, 2021, 27: 3685–3700
  - 105 Bilal A, Jourabloo A, Ye M, et al. Do convolutional neural networks learn class hierarchy? *IEEE Trans Visual Comput Graph*, 2018, 24: 152–162
  - 106 Qin Z, Yu F, Liu C, et al. How convolutional neural network see the world—a survey of convolutional neural network visualization methods. *Math Found Comput*, 2018, 1: 149–180
  - 107 Du M, Liu N, Hu X. Techniques for interpretable machine learning. *Commun ACM*, 2019, 63: 68–77
  - 108 Fong R C, Vedaldi A. Interpretable explanations of black boxes by meaningful perturbation. In: *Proceedings of the IEEE International Conference on Computer Vision*, 2017. 3429–3437
  - 109 Dabkowski P, Gal Y. Real time image saliency for black box classifiers. In: *Proceedings of the International Conference on Neural Information Processing Systems*, 2017. 6970–6979
  - 110 Zeiler M D, Fergus R. Visualizing and understanding convolutional networks. In: *Proceedings of the European Conference on Computer Vision*, 2014. 818–833
  - 111 Springenberg J T, Dosovitskiy A, Brox T, et al. Striving for simplicity: the all convolutional net. 2014 ArXiv:1412.6806
  - 112 Simonyan K, Vedaldi A, Zisserman A. Deep inside convolutional networks: visualising image classification models and saliency maps. 2013. ArXiv:1312.6034
  - 113 Bach S, Binder A, Montavon G, et al. On pixel-wise explanations for non-linear classifier decisions by layer-wise relevance propagation. *Plos One*, 2015, 10: e0130140
  - 114 Ancona M, Ceolini E, Öztireli C, et al. Towards better understanding of gradient-based attribution methods for deep neural networks. In: *Proceedings of the International Conference on Learning Representations*, 2018
  - 115 Li G, Wang J, Shen H W, et al. CNNPruner: pruning convolutional neural networks with visual analytics. *IEEE Trans Visual Comput Graph*, 2021, 27: 1364–1373
  - 116 Mahendran A, Vedaldi A. Visualizing deep convolutional neural networks using natural pre-images. *Int J Comput Vis*, 2016, 120: 233–255
  - 117 Dosovitskiy A, Brox T. Inverting visual representations with convolutional networks. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016. 4829–4837
  - 118 Mahendran A, Vedaldi A. Understanding deep image representations by inverting them. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2015. 5188–5196
  - 119 Erhan D, Bengio Y, Courville A, et al. Visualizing Higher-layer Features of a Deep Network. Technical Report, University of Montreal, 2009, 1341: 1
  - 120 Yosinski J, Clune J, Nguyen A, et al. Understanding neural networks through deep visualization. 2015. ArXiv:1506.06579
  - 121 Nguyen A, Dosovitskiy A, Yosinski J, et al. Synthesizing the preferred inputs for neurons in neural networks via deep generator networks. 2016. ArXiv:1605.09304
  - 122 Nguyen A, Yosinski J, Clune J. Understanding neural networks via feature visualization: a survey. In: *Explainable AI: Interpreting, Explaining and Visualizing Deep Learning*. Cham: Springer, 2019. 55–76

- 123 Bau D, Zhou B, Khosla A, et al. Network dissection: quantifying interpretability of deep visual representations. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017. 6541–6549
- 124 Fong R, Vedaldi A. Net2vec: quantifying and explaining how concepts are encoded by filters in deep neural networks. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018. 8730–8738
- 125 Smilkov D, Carter S, Sculley D, et al. Direct-manipulation visualization of deep networks. 2017. ArXiv:1708.03788
- 126 Abadi M, Agarwal A, Barham P, et al. Tensorflow: large-scale machine learning on heterogeneous distributed systems. 2016. ArXiv:1603.04467
- 127 Liu M, Shi J, Li Z, et al. Towards better analysis of deep convolutional neural networks. IEEE Trans Visual Comput Graph, 2017, 23: 91–100
- 128 Liu M, Shi J, Cao K, et al. Analyzing the training processes of deep generative models. IEEE Trans Visual Comput Graph, 2018, 24: 77–87
- 129 Liu M, Liu S, Su H, et al. Analyzing the noise robustness of deep neural networks. In: Proceedings of the IEEE Conference on Visual Analytics Science and Technology, 2018. 60–71
- 130 Shen Q, Wu Y, Jiang Y, et al. Visual interpretation of recurrent neural network on multi-dimensional time-series forecast. In: Proceedings of the IEEE Pacific Visualization Symposium, 2020. 61–70
- 131 Liu D, Cui W, Jin K, et al. DeepTracker: visualizing the training process of convolutional neural networks. ACM Trans Intell Syst Technol, 2019, 10: 1–25
- 132 Wongsuphasawat K, Smilkov D, Wexler J, et al. Visualizing dataflow graphs of deep learning models in tensorflow. IEEE Trans Visual Comput Graph, 2018, 24: 1–12
- 133 Hohman F, Park H, Robinson C, et al. Summit: scaling deep learning interpretability by visualizing activation and attribution summarizations. IEEE Trans Visual Comput Graph, 2020, 26: 1096–1106
- 134 Nie S, Healey C, Padia K, et al. Visualizing deep neural networks for text analytics. In: Proceedings of the IEEE Pacific Visualization Symposium, 2018. 180–189
- 135 Kahng M, Andrews P Y, Kalro A, et al. ACTIVIS: visual exploration of industry-scale deep neural network models. IEEE Trans Visual Comput Graph, 2018, 24: 88–97
- 136 Rauber P E, Fadel S G, Falcao A X, et al. Visualizing the hidden activity of artificial neural networks. IEEE Trans Visual Comput Graph, 2017, 23: 101–110
- 137 Zhang J, Wang Y, Molino P, et al. Manifold: a model-agnostic framework for interpretation and diagnosis of machine learning models. IEEE Trans Visual Comput Graph, 2019, 25: 364–373
- 138 Murugesan S, Malik S, Du F, et al. DeepCompare: visual and interactive comparison of deep learning model performance. IEEE Comput Graph Appl, 2019, 39: 47–59
- 139 Liu S, Li Z, Li T, et al. NLIZE: a perturbation-driven visual interrogation tool for analyzing and interpreting natural language inference models. IEEE Trans Visual Comput Graph, 2019, 25: 651–660
- 140 Ming Y, Xu P, Cheng F, et al. ProtoSteer: steering deep sequence model with prototypes. IEEE Trans Visual Comput Graph, 2020, 26: 238–248
- 141 Ming Y, Xu P, Qu H, et al. Interpretable and steerable sequence learning via prototypes. In: Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2019. 903–913
- 142 Kahng M, Thorat N, Chau D H P, et al. GAN Lab: understanding complex deep generative models using interactive visual experimentation. IEEE Trans Visual Comput Graph, 2019, 25: 310–320
- 143 Collaris D, van Wijk J J. ExplainExplore: visual exploration of machine learning explanations. In: Proceedings of the IEEE Pacific Visualization Symposium, 2020. 26–35
- 144 Wang J, Gou L, Zhang W, et al. DeepVID: deep visual interpretation and diagnosis for image classifiers via knowledge distillation. IEEE Trans Visual Comput Graph, 2019, 25: 2168–2180
- 145 Ming Y, Qu H, Bertini E. RuleMatrix: visualizing and understanding classifiers with rules. IEEE Trans Visual Comput Graph, 2019, 25: 342–352
- 146 Zeng W, Lin C, Lin J, et al. Revisiting the modifiable areal unit problem in deep traffic prediction with visual analytics. IEEE Trans Visual Comput Graph, 2021, 27: 839–848
- 147 Pezzotti N, Holtt T, van Gemert J, et al. DeepEyes: progressive visual analytics for designing deep neural networks. IEEE Trans Visual Comput Graph, 2018, 24: 98–108
- 148 Wang J, Zhang W, Yang H. SCANViz: interpreting the symbol-concept association captured by deep neural networks

- through visual analytics. In: Proceedings of the IEEE Pacific Visualization Symposium, 2020. 51–60
- 149 Cashman D, Perer A, Chang R, et al. Ablate, variate, and contemplate: visual analytics for discovering neural architectures. *IEEE Trans Visual Comput Graph*, 2020, 26: 863–873
  - 150 Wang X, Chen W, Xia J, et al. ConceptExplorer: visual analysis of concept drifts in multi-source time-series data. In: Proceedings of the IEEE Conference on Visual Analytics Science and Technology, 2020. 1–11
  - 151 Yang W, Li Z, Liu M, et al. Diagnosing concept drift with visual analytics. In: Proceedings of the IEEE Conference on Visual Analytics Science and Technology, 2020. 12–23
  - 152 Strobelt H, Gehrmann S, Pfister H, et al. LSTMVis: a tool for visual analysis of hidden state dynamics in recurrent neural networks. *IEEE Trans Visual Comput Graph*, 2018, 24: 667–676
  - 153 Cashman D, Patterson G, Mosca A, et al. RNNbow: visualizing learning via backpropagation gradients in RNNs. *IEEE Comput Graph Appl*, 2018, 38: 39–50
  - 154 Strobelt H, Gehrmann S, Behrisch M, et al. Seq2seq-vis: a visual debugging tool for sequence-to-sequence models. *IEEE Trans Visual Comput Graph*, 2019, 25: 353–363
  - 155 Jaunet T, Vuillemot R, Wolf C. DRLViz: understanding decisions and memory in deep reinforcement learning. *Comput Graph Forum*, 2020, 39: 49–61
  - 156 Wang J, Gou L, Shen H W, et al. DQNViz: a visual analytics approach to understand deep q-networks. *IEEE Trans Visual Comput Graph*, 2019, 25: 288–298
  - 157 Wang J, Gou L, Yang H, et al. GANViz: a visual analytics approach to understand the adversarial game. *IEEE Trans Visual Comput Graph*, 2018, 24: 1905–1917
  - 158 Fujiwara T, Chou J K, Shilpika J K, et al. An incremental dimensionality reduction method for visualizing streaming multidimensional data. *IEEE Trans Visual Comput Graph*, 2020, 26: 418–428
  - 159 Gortler J, Spinner T, Streeb D, et al. Uncertainty-aware principal component analysis. *IEEE Trans Visual Comput Graph*, 2020, 26: 822–831
  - 160 Watanabe K, Wu H Y, Niibe Y, et al. Biclustering multivariate data for correlated subspace mining. In: Proceedings of the IEEE Pacific Visualization Symposium, 2015. 287–294
  - 161 Liu S, Wang B, Thiagarajan J J, et al. Visual exploration of high-dimensional data through subspace analysis and dynamic projections. *Comput Graph Forum*, 2015, 34: 271–280
  - 162 Wang Y, Li J, Nie F, et al. Linear discriminative star coordinates for exploring class and cluster separation of high dimensional data. *Comput Graph Forum*, 2017, 36: 401–410
  - 163 Zhou F, Li J, Huang W, et al. Dimension reconstruction for visual exploration of subspace clusters in high-dimensional data. In: Proceedings of the IEEE Pacific Visualization Symposium, 2016. 128–135
  - 164 Zhou Z, Meng L, Tang C, et al. Visual abstraction of large scale geospatial origin-destination movement data. *IEEE Trans Visual Comput Graph*, 2019, 25: 43–53
  - 165 Zhu M, Chen W, Xia J, et al. Location2vec: a situation-aware representation for visual exploration of urban locations. *IEEE Trans Intell Transp Syst*, 2019, 20: 3981–3990
  - 166 Xie P, Tao W, Li J, et al. Exploring multi-dimensional data via subset embedding. *Comput Graph Forum*, 2021, 40: 75–86
  - 167 Kwon O H, Ma K L. A deep generative model for graph layout. *IEEE Trans Visual Comput Graph*, 2020, 26: 665–675
  - 168 Ma Y, Tung A K H, Wang W, et al. ScatterNet: a deep subjective similarity model for visual analysis of scatterplots. *IEEE Trans Visual Comput Graph*, 2020, 26: 1562–1576
  - 169 Jäckle D, Fischer F, Schreck T, et al. Temporal MDS plots for analysis of multivariate data. *IEEE Trans Visual Comput Graph*, 2016, 22: 141–150
  - 170 Haehn D, Tompkin J, Pfister H. Evaluating ‘graphical perception’ with CNNs. *IEEE Trans Visual Comput Graph*, 2019, 25: 641–650
  - 171 Krueger R, Beyer J, Jang W D, et al. Facetto: combining unsupervised and supervised learning for hierarchical phenotype analysis in multi-channel image data. *IEEE Trans Visual Comput Graph*, 2020, 26: 227–237
  - 172 Han J, Tao J, Wang C. FlowNet: a deep learning framework for clustering and selection of streamlines and stream surfaces. *IEEE Trans Visual Comput Graph*, 2020, 26: 1732–1744
  - 173 Berger M, McDonough K, Seversky L M. cite2vec: citation-driven document exploration via word embeddings. *IEEE Trans Visual Comput Graph*, 2017, 23: 691–700



- 174 Tkachev G, Frey S, Ertl T. Local prediction models for spatiotemporal volume visualization. *IEEE Trans Visual Comput Graph*, 2021, 27: 3091–3108
- 175 Maljovec D, Wang B, Rosen P, et al. Rethinking sensitivity analysis of nuclear simulations with topology. In: *Proceedings of the IEEE Pacific Visualization Symposium*, 2016. 64–71
- 176 Mafrur R, Sharaf M A, Khan H A. DiVE: diversifying view recommendation for visual data exploration. In: *Proceedings of the ACM International Conference on Information and Knowledge Management*, 2018. 1123–1132
- 177 Milo T, Somech A. Next-step suggestions for modern interactive data analysis platforms. In: *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2018. 576–585
- 178 Chen C, Wang C, Bai X, et al. GenerativeMap: visualization and exploration of dynamic density maps via generative learning model. *IEEE Trans Visual Comput Graph*, 2020, 26: 216–226
- 179 Berger M, Li J, Levine J A. A generative model for volume rendering. *IEEE Trans Visual Comput Graph*, 2019, 25: 1636–1650
- 180 Kim B, Günther T. Robust reference frame extraction from unsteady 2D vector fields with convolutional neural networks. *Comput Graph Forum*, 2019, 38: 285–295
- 181 Guo L, Ye S, Han J, et al. SSR-VFD: spatial super-resolution for vector field data analysis and visualization. In: *Proceedings of the IEEE Pacific Visualization Symposium*, 2020. 71–80
- 182 Zhang P, Li C, Wang C. VisCode: embedding information in visualization images using encoder-decoder network. *IEEE Trans Visual Comput Graph*, 2021, 27: 326–336
- 183 Ge T, Zhao Y, Lee B, et al. Canis: a high-level language for data-driven chart animations. *Comput Graph Forum*, 2020, 39: 607–617
- 184 Wang Y, Chen X, Ge T, et al. Optimizing color assignment for perception of class separability in multiclass scatterplots. *IEEE Trans Visual Comput Graph*, 2019, 25: 820–829
- 185 Lu K, Feng M, Chen X, et al. Palettaylor: discriminable colorization for categorical data. *IEEE Trans Visual Comput Graph*, 2021, 27: 475–484
- 186 Zheng J X, Pawar S, Goodman D F M. Graph drawing by stochastic gradient descent. *IEEE Trans Visual Comput Graph*, 2019, 25: 2738–2748
- 187 Wakita K, Takami M, Hosobe H. Interactive high-dimensional visualization of social graphs. In: *Proceedings of the IEEE Pacific Visualization Symposium*, 2015. 303–310
- 188 Weng D, Chen R, Deng Z, et al. SRVis: towards better spatial integration in ranking visualization. *IEEE Trans Visual Comput Graph*, 2019, 25: 459–469
- 189 Wu Y, Cao N, Archambault D, et al. Evaluation of graph sampling: a visualization perspective. *IEEE Trans Visual Comput Graph*, 2017, 23: 401–410
- 190 Chen X, Ge T, Zhang J, et al. A recursive subdivision technique for sampling multi-class scatterplots. *IEEE Trans Visual Comput Graph*, 2020, 26: 729–738
- 191 Zhao Y, Jiang H, Chen Q, et al. Preserving minority structures in graph sampling. *IEEE Trans Visual Comput Graph*, 2021, 27: 1698–1708
- 192 Zhou Z, Zhang X, Yang Z, et al. Visual abstraction of geographical point data with spatial autocorrelations. In: *Proceedings of the IEEE Conference on Visual Analytics Science and Technology*, 2020. 60–71
- 193 Zhou Z, Shi C, Shen X, et al. Context-aware sampling of large networks via graph representation learning. *IEEE Trans Visual Comput Graph*, 2021, 27: 1709–1719
- 194 Wang Y, Zhong Z, Hua J. DeepOrganNet: on-the-fly reconstruction and visualization of 3D/4D lung models from single-view projections by deep deformation network. *IEEE Trans Visual Comput Graph*, 2020, 26: 960–970
- 195 Hu R, Sha T, van Kaick O, et al. Data sampling in multi-view and multi-class scatterplots via set cover optimization. *IEEE Trans Visual Comput Graph*, 2020, 26: 739–748
- 196 Wang Y H, Chu X W, Zhang K Y, et al. ShapeWordle: tailoring wordles using shape-aware archimedean spirals. *IEEE Trans Visual Comput Graph*, 2020, 26: 991–1000
- 197 Bae J, Helldin T, Riveiro M. Understanding indirect causal relationships in node-link graphs. *Comput Graph Forum*, 2017, 36: 411–421
- 198 Bhowmick S S, Huang K, Chua H E, et al. AURORA: data-driven construction of visual graph query interfaces for graph databases. In: *Proceedings of the ACM SIGMOD International Conference on Management of Data*, 2020.

- 2689–2692
- 199 Song Y, Chua H E, Bhowmick S S, et al. BOOMER: a tool for blending visual p-homomorphic queries on large networks. In: *Proceedings of the ACM SIGMOD International Conference on Management of Data*, 2020. 2685–2688
  - 200 Meng Y, Zhang H, Liu M, et al. Clutter-aware label layout. In: *Proceedings of the IEEE Pacific Visualization Symposium*, 2015. 207–214
  - 201 Chen X, Zeng W, Lin Y, et al. Composition and configuration patterns in multiple-view visualizations. *IEEE Trans Visual Comput Graph*, 2021, 27: 1514–1524
  - 202 Fan C, Hauser H. Fast and accurate CNN-based brushing in scatterplots. *Comput Graphics Forum*, 2018, 37: 111–120
  - 203 Chen Z, Zeng W, Yang Z, et al. LassoNet: deep lasso-selection of 3D point clouds. *IEEE Trans Visual Comput Graphics*, 2019, 26: 195–204
  - 204 Ottley A, Garnett R, Wan R. Follow the clicks: learning and anticipating mouse interactions during exploratory data analysis. *Comput Graph Forum*, 2019, 38: 41–52
  - 205 Savvides R, Henelius A, Oikarinen E, et al. Significance of patterns in data visualisations. In: *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2019. 1509–1517
  - 206 Gao L, Cao Y P, Lai Y K, et al. Active exploration of large 3D model repositories. *IEEE Trans Visual Comput Graph*, 2015, 21: 1390–1402
  - 207 Hazarika S, Li H, Wang K C, et al. NNVA: neural network assisted visual analysis of yeast cell polarization simulation. *IEEE Trans Visual Comput Graph*, 2019, 26: 34–44
  - 208 Zhang L, Alghamdi N, Eltabakh M Y, et al. Big data series analytics using TARDIS and its exploitation in geospatial applications. In: *Proceedings of the ACM SIGMOD International Conference on Management of Data*, 2020. 2785–2788
  - 209 Hong F, Liu C, Yuan X. DNN-VolVis: interactive volume visualization supported by deep neural network. In: *Proceedings of the IEEE Pacific Visualization Symposium*, 2019. 282–291
  - 210 Huang Z, Zhao Y, Chen W, et al. A natural-language-based visual query approach of uncertain human trajectories. *IEEE Trans Visual Comput Graph*, 2019, 26: 1256–1266
  - 211 Wang Z, Ferreira N, Wei Y, et al. Gaussian Cubes: real-time modeling for visual exploration of large multidimensional datasets. *IEEE Trans Visual Comput Graph*, 2017, 23: 681–690
  - 212 Mei H, Chen W, Wei Y, et al. RSATree: distribution-aware data representation of large-scale tabular datasets for flexible visual query. *IEEE Trans Visual Comput Graph*, 2020, 26: 1161–1171
  - 213 Liu C, Wu C, Shao H, et al. SmartCube: an adaptive data management architecture for the real-time visualization of spatiotemporal datasets. *IEEE Trans Visual Comput Graph*, 2020, 26: 790–799
  - 214 Dong L, Bai Q, Kim T, et al. Marviq: quality-aware geospatial visualization of range-selection queries using materialization. In: *Proceedings of the ACM SIGMOD International Conference on Management of Data*, 2020. 67–82
  - 215 Lin Q, Ke W, Lou J G, et al. BigIN4: instant, interactive insight identification for multi-dimensional big data. In: *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2018. 547–555
  - 216 Li J, Chen S, Chen W, et al. Semantics-space-time cube: a conceptual framework for systematic analysis of texts in space and time. *IEEE Trans Visual Comput Graph*, 2020, 26: 1789–1806
  - 217 El-Assady M, Sevastjanova R, Gipp B, et al. NEREx: named-entity relationship exploration in multi-party conversations. *Comput Graphics Forum*, 2017, 36: 213–225
  - 218 El-Assady M, Kehlbeck R, Collins C, et al. Semantic concept spaces: guided topic model refinement using word-embedding projections. *IEEE Trans Visual Comput Graph*, 2020, 26: 1001–1011
  - 219 Guo H, Laidlaw D H. Topic-based exploration and embedded visualizations for research idea generation. *IEEE Trans Visual Comput Graph*, 2020, 26: 1592–1607
  - 220 Leventidis A, Zhang J, Dunne C, et al. QueryVis: logic-based diagrams help users understand complicated SQL queries faster. In: *Proceedings of the ACM SIGMOD International Conference on Management of Data*, 2020. 2303–2318
  - 221 Xu P, Cao N, Qu H, et al. Interactive visual co-cluster analysis of bipartite graphs. In: *Proceedings of the IEEE Pacific Visualization Symposium*, 2016. 32–39
  - 222 Wu T H, Zhao Y, Amiruzzaman M. Interactive visualization of AI-based speech recognition texts. In: *Proceedings of the International EuroVis Workshop on Visual Analytics*, 2020. 79–83

- 223 Cui W, Zhang X, Wang Y, et al. Text-to-viz: automatic generation of infographics from proportion-related natural language statements. *IEEE Trans Visual Comput Graph*, 2020, 26: 906–916
- 224 Wang Y, Sun Z, Zhang H, et al. DataShot: automatic generation of fact sheets from tabular data. *IEEE Trans Visual Comput Graph*, 2020, 26: 895–905
- 225 Zeng H, Wang X, Wu A, et al. EmoCo: visual analysis of emotion coherence in presentation videos. *IEEE Trans Visual Comput Graph*, 2020, 26: 927–937
- 226 Shi Y, Bryan C, Bhamidipati S, et al. Meetingvis: visual narratives to assist in recalling meeting context and content. *IEEE Trans Visual Comput Graph*, 2018, 24: 1918–1929
- 227 Tang T, Rubab S, Lai J, et al. iStoryline: effective convergence to hand-drawn storylines. *IEEE Trans Visual Comput Graph*, 2019, 25: 769–778
- 228 Lai C, Lin Z, Jiang R, et al. Automatic annotation synchronizing with textual description for visualization. In: *Proceedings of the CHI Conference on Human Factors in Computing Systems*, 2020. 1–13
- 229 Liu C, Xie L, Han Y, et al. AutoCaption: an approach to generate natural language description from visualization automatically. In: *Proceedings of the IEEE Pacific Visualization Symposium*, 2020. 191–195
- 230 Wang R, Wei Z, Li P, et al. Storytelling from an image stream using scene graphs. In: *Proceedings of the AAAI Conference on Artificial Intelligence*, 2020. 9185–9192
- 231 Chen S, Li J, Andrienko G, et al. Supporting story synthesis: bridging the gap between visual analytics and storytelling. *IEEE Trans Visual Comput Graph*, 2020, 26: 2499–2516
- 232 Yang P, Luo F, Chen P, et al. Knowledgeable storyteller: a commonsense-driven generative model for visual storytelling. In: *Proceedings of the International Joint Conference on Artificial Intelligence*, 2019. 5356–5362
- 233 Chen Z, Wang Y, Wang Q, et al. Towards automated infographic design: deep learning-based auto-extraction of extensible timeline. *IEEE Trans Visual Comput Graph*, 2020, 26: 917–926
- 234 Jung Y, Kim D, Woo S, et al. Hide-and-tell: learning to bridge photo streams for visual storytelling. In: *Proceedings of the AAAI Conference on Artificial Intelligence*, 2020. 11213–11220
- 235 Hu J, Cheng Y, Gan Z, et al. What makes a good story? Designing composite rewards for visual storytelling. In: *Proceedings of the AAAI Conference on Artificial Intelligence*, 2020. 7969–7976
- 236 Fulda J, Brehmer M, Munzner T. TimeLineCurator: interactive authoring of visual timelines from unstructured text. *IEEE Trans Visual Comput Graph*, 2016, 22: 300–309
- 237 Hu S-M, Liang D, Yang G-Y, et al. Jittor: a novel deep learning framework with meta-operators and unified graph execution. *Sci China Inf Sci*, 2020, 63: 222103

# A survey on interdisciplinary research of visualization and artificial intelligence

Jiazhi XIA<sup>1\*</sup>, Jie LI<sup>2\*</sup>, Siming CHEN<sup>3</sup>, Hongxing QIN<sup>4</sup> & Shixia LIU<sup>5</sup>

1. School of Computer Science and Engineering, Central South University, Changsha 410083, China;

2. College of Intelligence and Computing, Tianjin University, Tianjin 300072, China;

3. School of Data Science, Fudan University, Shanghai 200433, China;

4. College of Computer Science, Chongqing University, Chongqing 400044, China;

5. School of Software, Tsinghua University, Beijing 100083, China

\* Corresponding author. E-mail: xiajiazhi@csu.edu.cn, jie.li@tju.edu.cn

**Abstract** With the breakthroughs in artificial intelligence (AI) technology, interdisciplinary research across AI and visualization (AI+VIS) has become one of the current research hotspots, providing inspiring theories, methods, and techniques for several core challenges in AI and big data analytics. On one hand, the innovative application of artificial intelligence technology has improved the efficiency of visualization, expanded the analysis capabilities, and provided powerful tools for big data visualization and analysis. On the other hand, visualization techniques enhance the explainability and interactivity of AI represented by deep learning, providing a reliable technical foundation for explainable AI. This paper introduces six important topics, including data quality improvement, explainable machine learning, intelligent feature extraction, automatic visualization layout and generation, intelligent interaction, and intelligent storytelling from two directions of “VIS for AI” and “AI for VIS”, respectively. The research progress in the recent three years is analyzed. We also highlight the research trends of AI+VIS.

**Keywords** visualization, visual analytics, artificial intelligence, explainable machine learning, automatic visualization



**Jiazhi XIA** is a professor in the School of Computer Science and Engineering at Central South University. He received his Ph.D. degree in computer science from Nanyang Technological University, Singapore in 2011 and obtained his M.S. and B.S. degrees in computer science and technology from Zhejiang University in 2008 and 2005, respectively. His research interests include data visualization, visual analytics, and computer graphics.



**Jie LI** is an associate professor at the College of Intelligence and Computing of Tianjin University. His current research interests include interactive exploration of big data and human-supervised machine learning.



**Siming CHEN** is an associate professor in the School of Data Science at Fudan University. He received his Ph.D. degree from Peking University in computer science. His research interests include general visual analytics and visualization, social media, cyber security, and spatial-temporal data analysis.



**Shixia LIU** is an associate professor at Tsinghua University. She received her B.S. and M.S. degrees from Harbin Institute of Technology, and her Ph.D. degree from Tsinghua University. She has worked as a research staff member at IBM China Research Lab and a lead researcher at Microsoft Research Asia. Her research interests include visual text analytics, visual social analytics, interactive machine learning, and text mining.